UST 과학기술연합대학원대학교
UNIVERSITY OF SCIENCE & TECHNOLOGY

인공지능 일반강좌 : 기계학습의 이해(L2-1)

5강: SVM의 이해

Contents

SVM의 역사

- SVM은 통계 학습 이론과 관련
  - ✓ SVM은 1992년에 처음 소개됨
  - ✓ SVM은 손글씨 인식 문제에서 성능을 보임
  - ✓ SVM의 테스트 오차율은 1.1%로, 신경망 LeNet 4과 비슷한 성능
- SVM의 'kernel trick'은 머신러닝의 주요 분야

선형분리와 비선형 분리 예제

샘플의 선형적 분리 예제

linearly separable

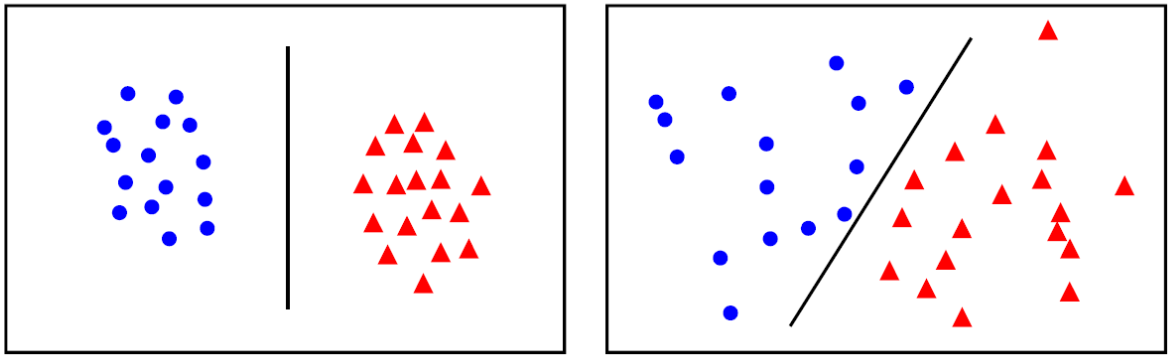

not linearly separable

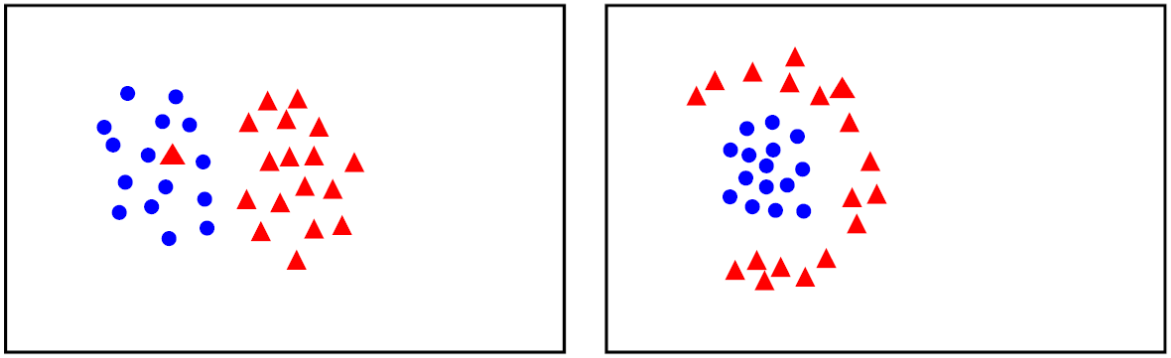

무엇인 결정 경계인가?

- 결정 경계 (decision boundary)
  - ✓ 아래 그림처럼 2개의 범주를 나누는 선형 분리가 가능할 때,
  - ✓ 많은 결정 경계가 가능하다.
  - ✓ 어떤 선이 가장 적절하게 두 데이터를 구분한 선일까요?

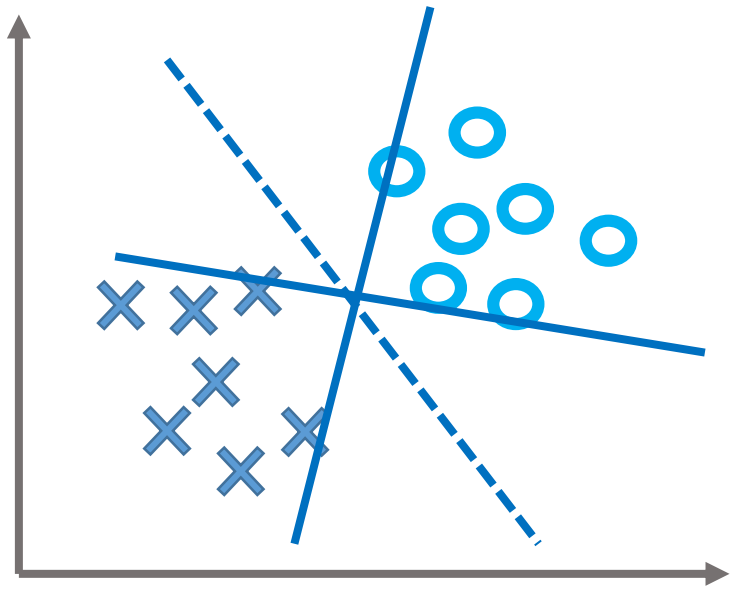

마진(margin)이란 무엇인가?

- 마진(margin)은 두 경계면 사이의 거리임.
  - ✓ 이 거리(마진)가 최대가 되도록 파라미터(기울기, 편향)를 최적화 하자.
  - ✓ '+'와 '–' 샘플 사이의 거리를 가장 넓게하는 어떤 선(점선)

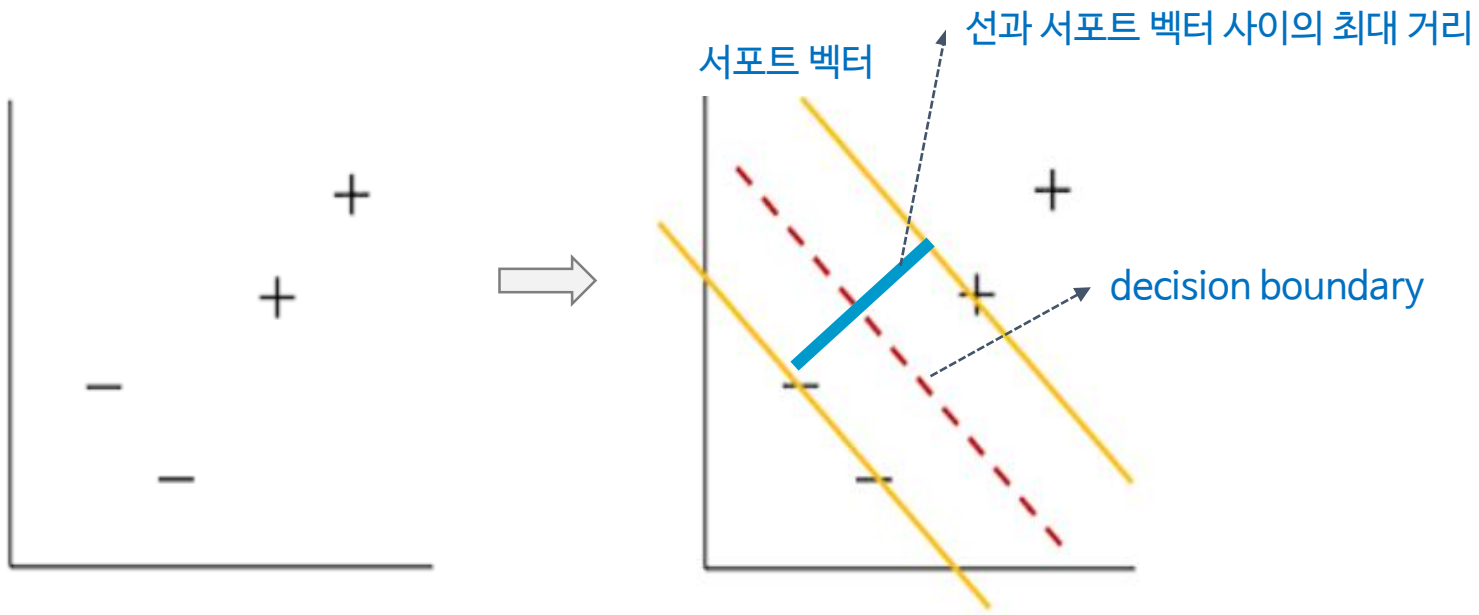

결정 경계(구분선) 결정 규칙(1)

- SVM 분류기는 결정함수를 계산해서 새로운 샘플 x의 클래스를 예측함

$$\mathbf{w}^T \mathbf{x} + b = w_1 x_1 + \cdots + w_n x_n + b$$

✓ 결과가 0보다 크면 양성(+), 그렇지 않으면 음성(-) 클래스

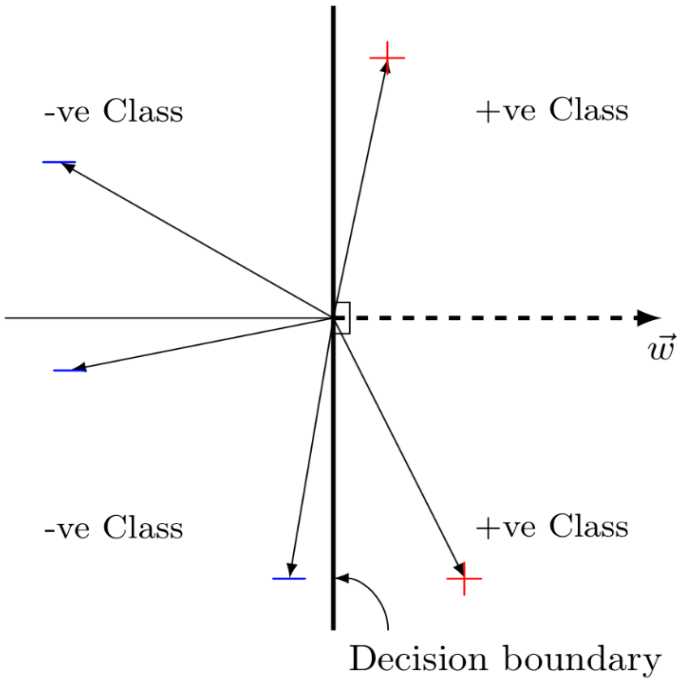

$\vec{w} \cdot \vec{x} > c$ then '+'
$c = -b$

$\vec{w} \cdot \vec{x} + b > 0$ then '+'

내적은 |w||u|코사인이므로
결정경계 오른쪽이 +, 왼쪽이 - 이다.

선형 SVM 분류기의 예측

Iris 데이터 셋의 결정 함수:
선형 SVM 분류기를 훈련하는 것은 마진 오류를 하나도 발생하지 않거나(하드마진),
제한적인 마진 오류를 가지면서(소프트마진) 가능한 마진을 크게하는 (w,b)를 찾는 것이다.

$$\hat{y} = \begin{cases} 0 \text{ if } \mathbf{w}^T\mathbf{x} + b < 0, \\ 1 \text{ if } \mathbf{w}^T\mathbf{x} + b \geq 0 \end{cases}$$

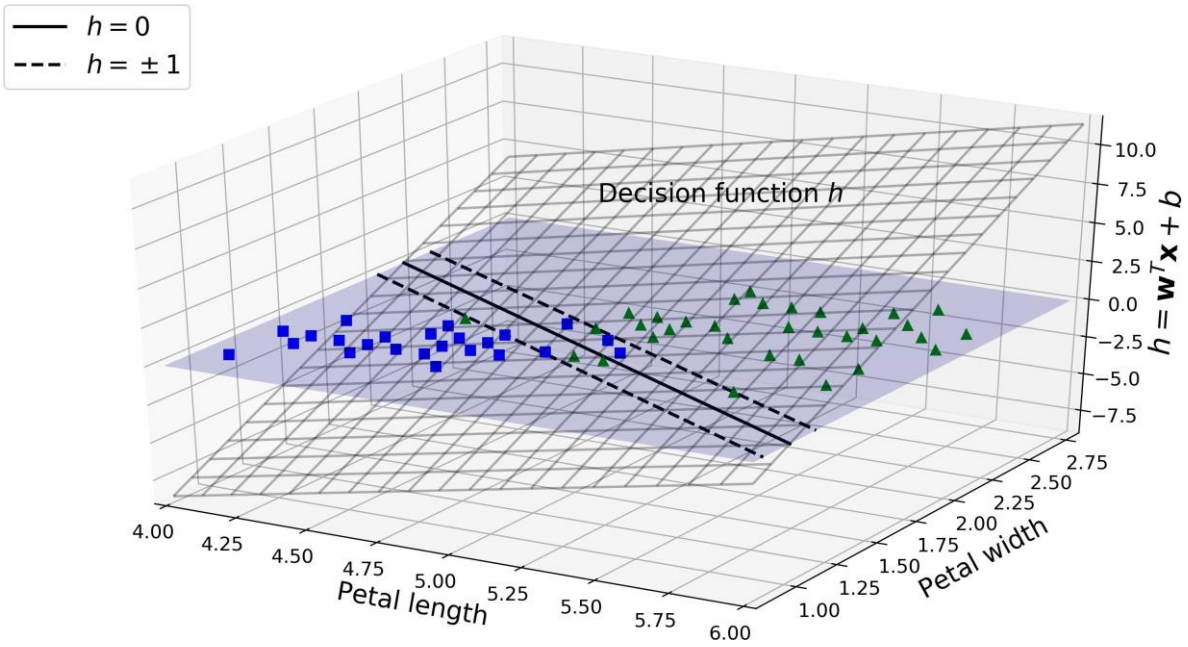

목적함수

- 결정함수의 기울기를 생각해보면 이는 가중치 벡터의 놈 ||w||와 같다.
- 가중치 벡터 w가 작을 수록 마진은 커진다.
  - ✓ 기울기를 2로 나누면 결정함수 +1/(−1)되는 점들이 2배 늘어난다.
  - ✓ 즉, 기울기를 2로 나누는 것은 마진에 2를 곱한 것과 같다.
- 마진을 크게하기위해 ||w||를 최소화

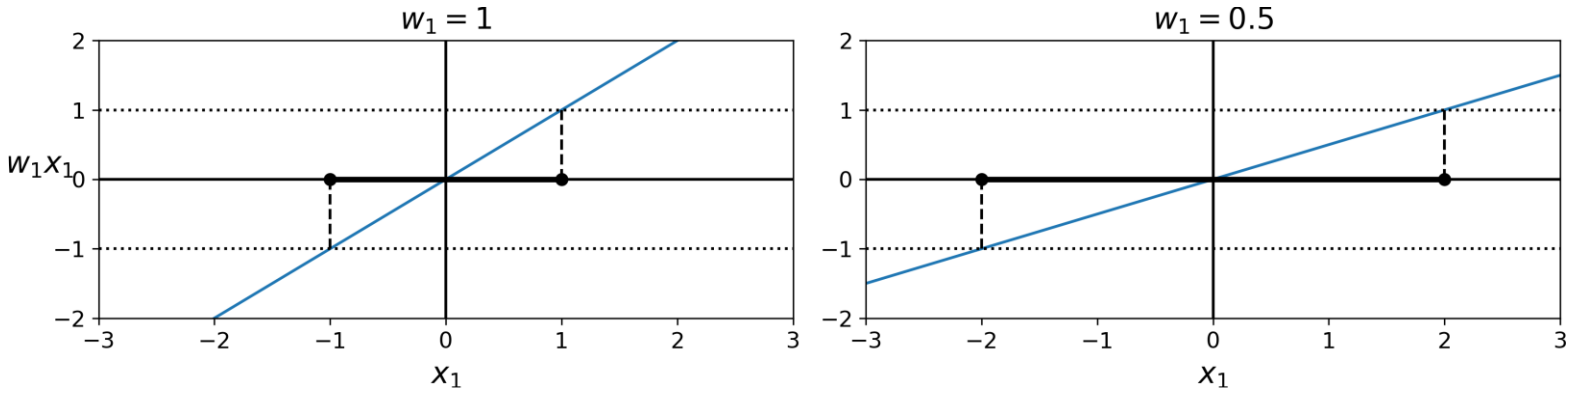

마진을 최대화 하는 방법

어떤 선을 잡되 이로 인해 생기는 +와 - 샘플 사이의 거리를 가능한 최대로 넓게 하려면?

$$\vec{w} \cdot \vec{x^+} + b > 1$$
$$\vec{w} \cdot \vec{x^-} + b > -1$$

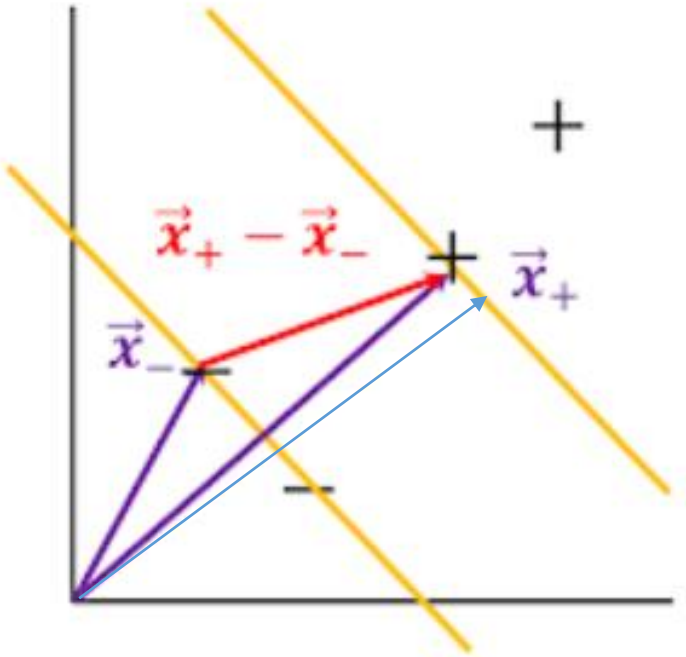

$$x^+ = x^- + \lambda w$$

구분선에 대한 법선 벡터(w)의 크기는 스칼라(w)이고, 람다는 임의의 계수이다. 두 개의 샘플 사이의 거리인 빨강색 선 크기이고, 이 값은 법선벡터 쪽으로 내적한 크기와 관련됨

$$w^T x^+ + b = 1$$
$$w^T (x^- + \lambda w) + b = 1$$
$$w^T x^- + b + \lambda w^T w = 1$$
$$-1 + \lambda w^T w = 1$$

$$\lambda = \frac{2}{w^T w}$$

결정 경계(구분선) 결정

마진은 결정 경계 두 샘플 거리가 최대가 되도록 정한다.

$$\lambda = \frac{2}{w^T w}$$

$$\begin{aligned} Margin &= distance(x^+, x^-) \\ &= \left\| x^+ - x^- \right\|_2 \\ &= \left\| x^- + \lambda w - x^- \right\|_2 \\ &= \left\| \lambda w \right\|_2 \\ &= \lambda \sqrt{w^T w} \\ &= \frac{2}{w^T w} \sqrt{w^T w} \\ &= \frac{2}{\sqrt{w^T w}} \\ &= \frac{2}{\left\| w \right\|_2} \end{aligned}$$

하드 마진 선형 SVM 분류기의 목적함수

- **SVM의 목적은 마진을 최대화하는 경계면을 찾는 것**
  - ✓ **마진을 최대화 한다는 것은 기울기 제곱을 최소화 한다는 것과 같고,**
  - ✓ **여기엔 다음과 같은 제약조건이 관측치 개수만큼 붙습니다.**
    - (조건) i=1,2,3,⋯,m

$$max \frac{2}{\|w\|_2} \rightarrow \min \frac{1}{2}\|w\|_2^2$$

$$y_i(w^T x_i + b) \geq 1$$

라그랑지안 문제로 변환

- 라그랑지안 승수법(Lagrange multiplier method)
  - ✓ 제약식에 형식적인 라그랑지안 승수를 곱한 항을 최적화하려는 목적식에 더하여, 제약된 문제를 제약이 없는 문제로 바꾸는 기법입니다
  - ✓ 정의한 목적식과 제약식을 라그랑지안 문제로 식을 다시 쓰면

$$\min L_p(w, b, \alpha_i) = \frac{1}{2}\|w\|_2^2 - \sum_{i=1}^{n} \alpha_i (y_i(w^T x_i + b) - 1)$$

  - ✓ 라그랑지안 함수의 최소값을 주는 계수(alpha를 찾자)
    - 법선벡터(w)에 2차 함수 모양으로 1개의 전역(Global) 최소점이 있다.

$$\alpha_i \geq 0, \quad i = 1, \ldots, n$$

라그랑지안 해를 구하기

쿼드락틱 프로그램밍(QP):
하드(소프트) 마진 문제는 선형적인 제약조건이 있는 볼록함수의 이차 최적화 문제

$$\nabla_{\vec{w}}\mathcal{L} = \vec{w} - \sum_i \alpha_i y_i \vec{x}_i = 0 \quad \Longrightarrow \quad \vec{w} = \sum_i \alpha_i y_i \vec{x}_i$$

$$\nabla_b \mathcal{L} = -\sum_i \alpha_i y_i = 0$$

해석하면,
결정벡터가 '어떤' 샘플의 선형 합이다.

이제, 라그랑쥐 멀티플라이어만 알면 되는데,

$$\sum_{i=1}^{N} \alpha_i + \frac{1}{2}||\vec{w}||^2 - \sum_{i=1}^{N} \alpha_i y_i \vec{w}^T \vec{x}_i \iff \sum_{i=1}^{N} \alpha_i + \frac{1}{2}\vec{w}^T\vec{w} - \vec{w}^T\vec{w}$$

$$\iff \sum_{i=1}^{N} \alpha_i - \frac{1}{2}\vec{w}^T\vec{w}$$

$$\iff \sum_{i=1}^{N} \alpha_i - \frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N} \alpha_i \alpha_j y_i y_j \vec{x}_i^T \vec{x}_j$$

$$\iff \mathcal{L}(\alpha).$$

2차함수 성격으로 quadratic programming로 해를 구함

SVM의 해

- SVM의 해는 마진이 최대화 된 분류경계면의 w와 b를 찾자.

$$w = \sum_{i=1}^{n} \alpha_i y_i x_i$$

x_i, y_i는 알고 있는 학습 데이터

✓ 함수가 최적값을 갖는다면 아래 두 개 가운데 하나는 반드시 0입니다

$$(1)\alpha_i$$
$$(2)y_i(w^T x_i + b) - 1$$
$$y_i(w^T x_i + b) - 1 = 0$$

✓ 위의 마지막 식은 알파(alpha)가 0이 아닌 경우로, 서포트 벡터라고 한다.

서포트 벡터 머신 (SVM)의 해

알파는 해당 벡터(x)가 경계선을 정하는 샘플이라는 뜻으로 “서포트 벡터 " 라고 부름

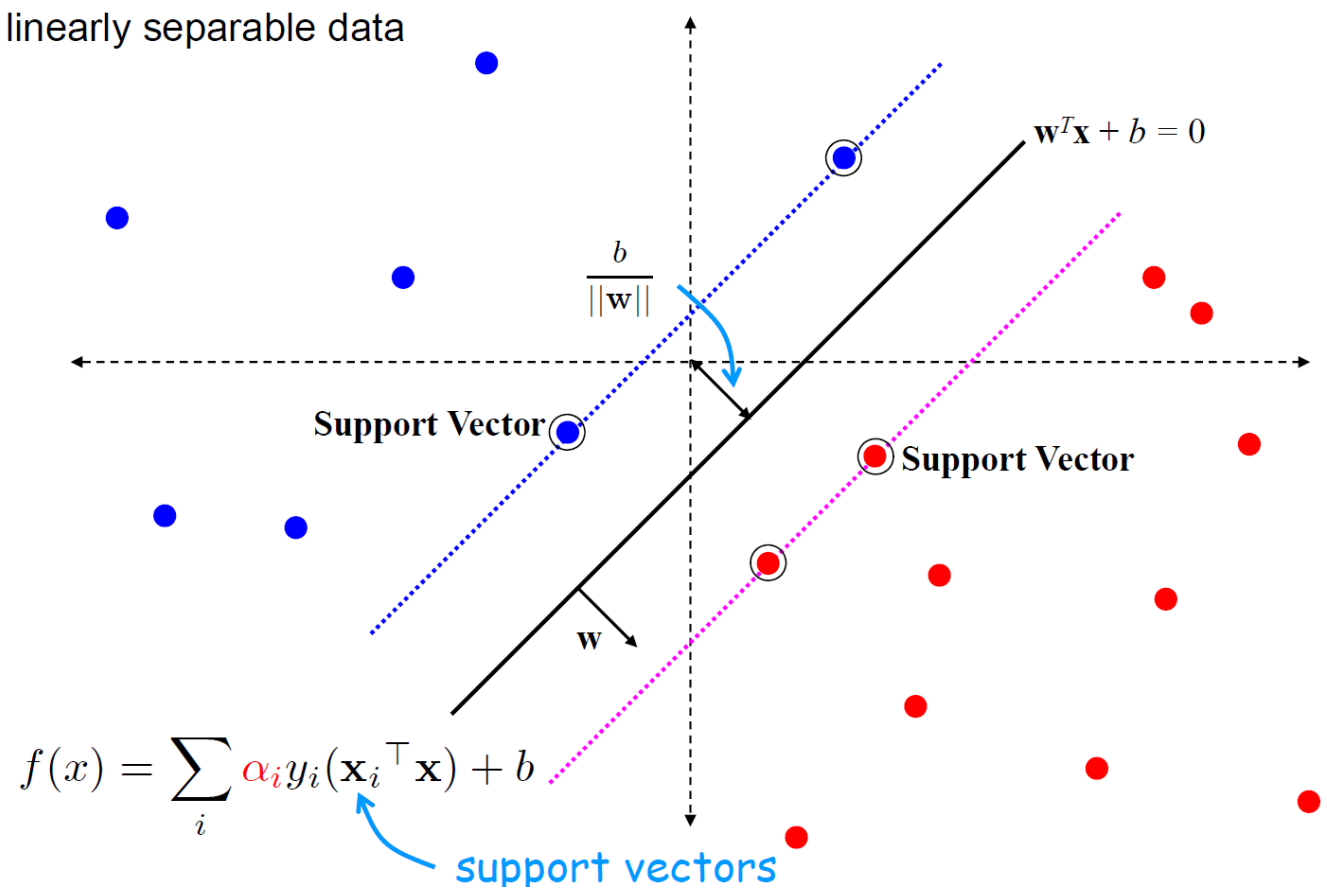

선형 SVM 분류

- SVM 정리
  - ✓ **직관적으로 자료를 군집별로 가장 잘 분리하는 초평면은 가장 가까운 훈련용 자료까지의 거리가 가장 큰 경우**
    - 최대 마진을 가지는 선형판별에 기초하며, 속성들 간의 의존성은 고려하지 않는 방법
    - 마진이 가장 큰 초평면을 분류기로 사용할 때, 새로운 자료에 대한 오분류가 가장 낮다

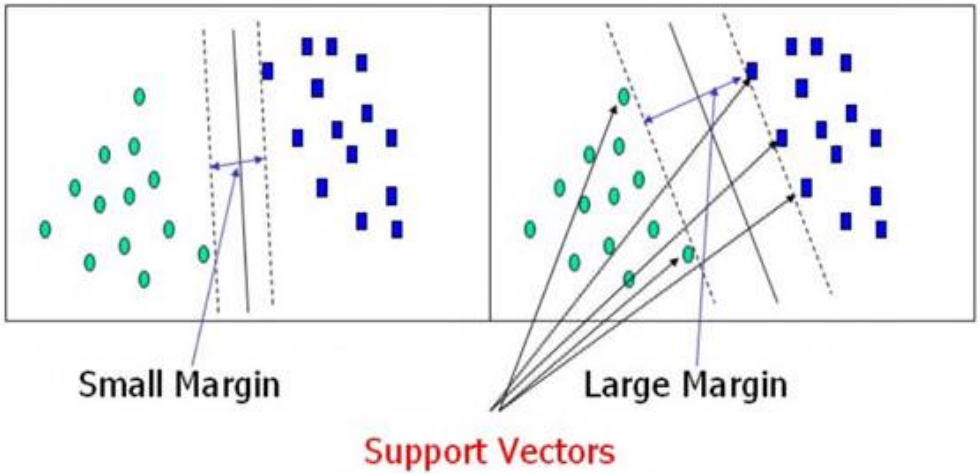

비선형 SVM

- 선형으로 분리 되지 않을 경우
  - ✓ 원공간(Input Space)의 데이터를 선형분류가 가능한 고차원 공간(Feature Space)으로 매핑한 뒤 두 범주를 분류하는 초평면을 찾는다.

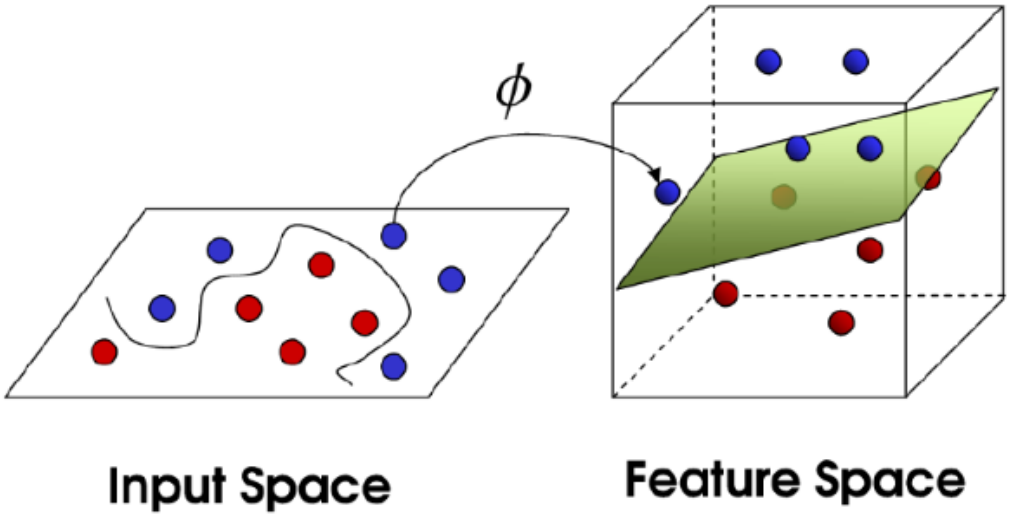

SVM의 커널 트릭

- 커널 트릭(kernel trick)
  - ✓ 입력 자료의 다차원 공간상으로의 맵핑(mapping) 기법을 사용하여 비선형분류도 효율적으로 수행
  - ✓ 고차원 매핑과 내적을 한방에 할 수는 커널 트릭

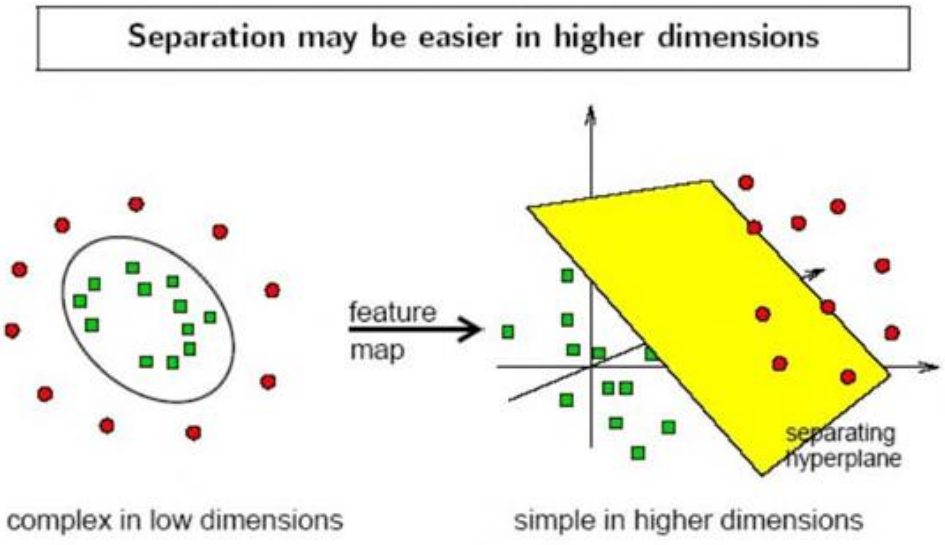

$$K(\vec{x}, \vec{y}) = \phi(\vec{x}) \cdot \phi(\vec{y})$$

Kernel trick:
SVM에서 커널은 내적임으로,
샘플 공간에서 선형적으로
나눌 수 있는 공간을 샘플을
보내주고 SVM을 적용함.

쌍대 문제(Dual Problem)

- **원 문제(Primal problem)라는 제약이 있는 최적화 문제가 주어지면 쌍대 문제라고 하는 깊게 관련된 다른 문제로 표현**
  - ✓ **다행히, SVM은 원 문제나 쌍대 문제나 하나를 풀면 된다. 둘 다 같은 해를 줌.**
  - ✓ **훈련 샘플 수가 특성 개수 보다 작을 때 원 문제보다 쌍대 문제를 푸는 게 더 빠름.**
    - 선형 SVM 목적 함수의 쌍대 형식

$$\underset{\alpha}{\text{minimize}} \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha^{(i)}\alpha^{(j)}t^{(i)}t^{(j)}\mathbf{x}^{(i)T}\mathbf{x}^{(j)} - \sum_{i=1}^{m}\alpha^{(i)}$$

$$\text{subject to} \quad \alpha^{(i)} \geq 0 \quad \text{for } i = 1, 2, \cdots, m$$

    - 쌍대 문제에서 구한 해로 원 문제 해 계산하기

$$\hat{\mathbf{w}} = \sum_{i=1}^{m}\hat{\alpha}^{(i)}t^{(i)}\mathbf{x}^{(i)}$$

$$\hat{b} = \frac{1}{n_s}\sum_{\substack{i=1 \\ \hat{\alpha}^{(i)} > 0}}^{m}\left(t^{(i)} - \hat{\mathbf{w}}^{T}\mathbf{x}^{(i)}\right)$$

커널 SVM (커널 트릭)

- **2차원 다항식 매핑**
  - ✓ **2차원 데이터 셋에 2차원 다항식 변환을 적용하고 선형 SVM 분류기를 변환된 이 훈련세트에 적용하면 3차원이 된다.**

$$\phi(\mathbf{x}) = \phi\left(\begin{pmatrix} x_1 \\ x_2 \end{pmatrix}\right) = \begin{pmatrix} {x_1}^2 \\ \sqrt{2}\, x_1 x_2 \\ {x_2}^2 \end{pmatrix}$$

  - 2개의 2차원 벡터 a,b에 2차 다항식 매핑을 적용 후 dot product하면 같다.

$$\phi(\mathbf{a})^T \phi(\mathbf{b}) = \begin{pmatrix} {a_1}^2 \\ \sqrt{2}\, a_1 a_2 \\ {a_2}^2 \end{pmatrix}^T \begin{pmatrix} {b_1}^2 \\ \sqrt{2}\, b_1 b_2 \\ {b_2}^2 \end{pmatrix} = {a_1}^2 {b_1}^2 + 2 a_1 b_1 a_2 b_2 + {a_2}^2 {b_2}^2$$

$$= (a_1 b_1 + a_2 b_2)^2 = \left(\begin{pmatrix} a_1 \\ a_2 \end{pmatrix}^T \begin{pmatrix} b_1 \\ b_2 \end{pmatrix}\right)^2 = \left(\mathbf{a}^T \mathbf{b}\right)^2$$

일반적인 커널

- **머신러닝에서 커널은 변환 ϕ를 계산하지 않고, 원래 벡터 a, b에 기반하여**
  - ✓ **점곱(dot product)를 계산 할 수 있는 함수.**
    - 2차 다항식 커널

$$K(\mathbf{a}, \mathbf{b}) = (\mathbf{a}^T \mathbf{b})^2$$

    - 일반적인 커널

$$\begin{aligned}
\text{Linear:} \quad & K(\mathbf{a}, \mathbf{b}) = \mathbf{a}^T\mathbf{b} \\
\text{Polynomial:} \quad & K(\mathbf{a}, \mathbf{b}) = \left(\gamma \mathbf{a}^T\mathbf{b} + r\right)^d \\
\text{Gaussian RBF:} \quad & K(\mathbf{a}, \mathbf{b}) = \exp\left(-\gamma \| \mathbf{a} - \mathbf{b} \|^2\right) \\
\text{Sigmoid:} \quad & K(\mathbf{a}, \mathbf{b}) = \tanh\left(\gamma \mathbf{a}^T\mathbf{b} + r\right)
\end{aligned}$$

붓꽃에 LinearSVC 적용 (1)

마진과 서프트 벡터 이해하기

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```

```
from sklearn import datasets
from sklearn import svm
from sklearn.metrics import accuracy_score
from sklearn.preprocessing import PolynomialFeatures, StandardScaler
from sklearn.svm import LinearSVC
from sklearn.svm import SVC
from sklearn.model_selection import train_test_split
```

붓꽃에 LinearSVC 적용 (2)

```
iris = datasets.load_iris()
X = iris['data'][:,(2,3)]
```

Petal (꽃잎) 길이와 넓이

```
scaler = StandardScaler()
Xstan = scaler.fit_transform(X)

data = pd.DataFrame(data=Xstan,
       columns=['petal length','petal width'])
data['target'] = iris['target']
data = data[data['target']!=2]
# 0, 1에 관심 Iris-setosa and Iris-Versicolor
data.head()
```

	petal length	petal width	target
0	-1.340227	-1.315444	0
1	-1.340227	-1.315444	0
2	-1.397064	-1.315444	0
3	-1.283389	-1.315444	0
4	-1.340227	-1.315444	0

입력값을 정규분포에 맞도록 변화함

Target은 0 (Setosa)와 1 (Versicolor)를 사용함

질문) 붓꽃의 꽃잎 3종류가 있는데, 2종류 보다 3종류를 선택하는 것이 올바른 것인가? 어떻게 처리할 것인가?

붓꽃에 LinearSVC 적용 (3)

```
sns.lmplot(x='petal length',y='petal width',
           hue='target',data=data, fit_reg=False, legend=False)

plt.legend(['Iris-Setosa','Iris-Versicolor'], fontsize = 14)
plt.xlabel('petal length (scaled)', fontsize = 18)
plt.ylabel('petal width (scaled)', fontsize = 18)
plt.show()
```

Seaborn 가시화

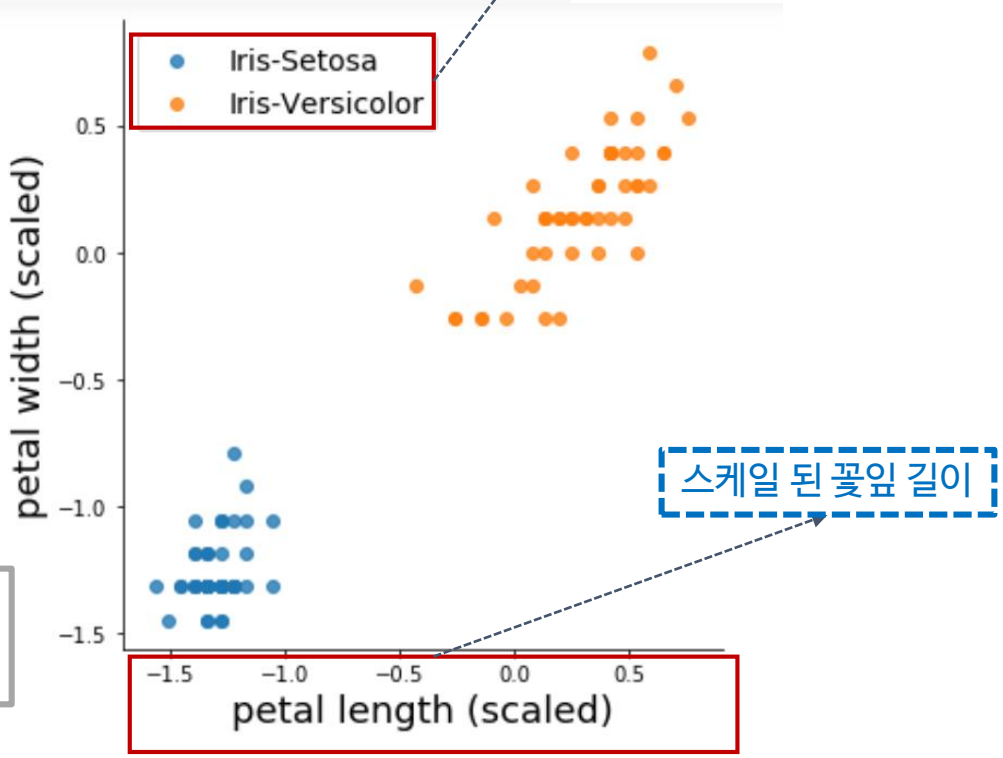

2종류 꽃잎이라서,
데이터가 잘 분리 되었음

스케일 된 꽃잎 길이

(질문) 3종류의 꽃잎일 경우?
또한, 3종류의 꽃받침(sepal)?

붓꽃에 LinearSVC 적용 (4)

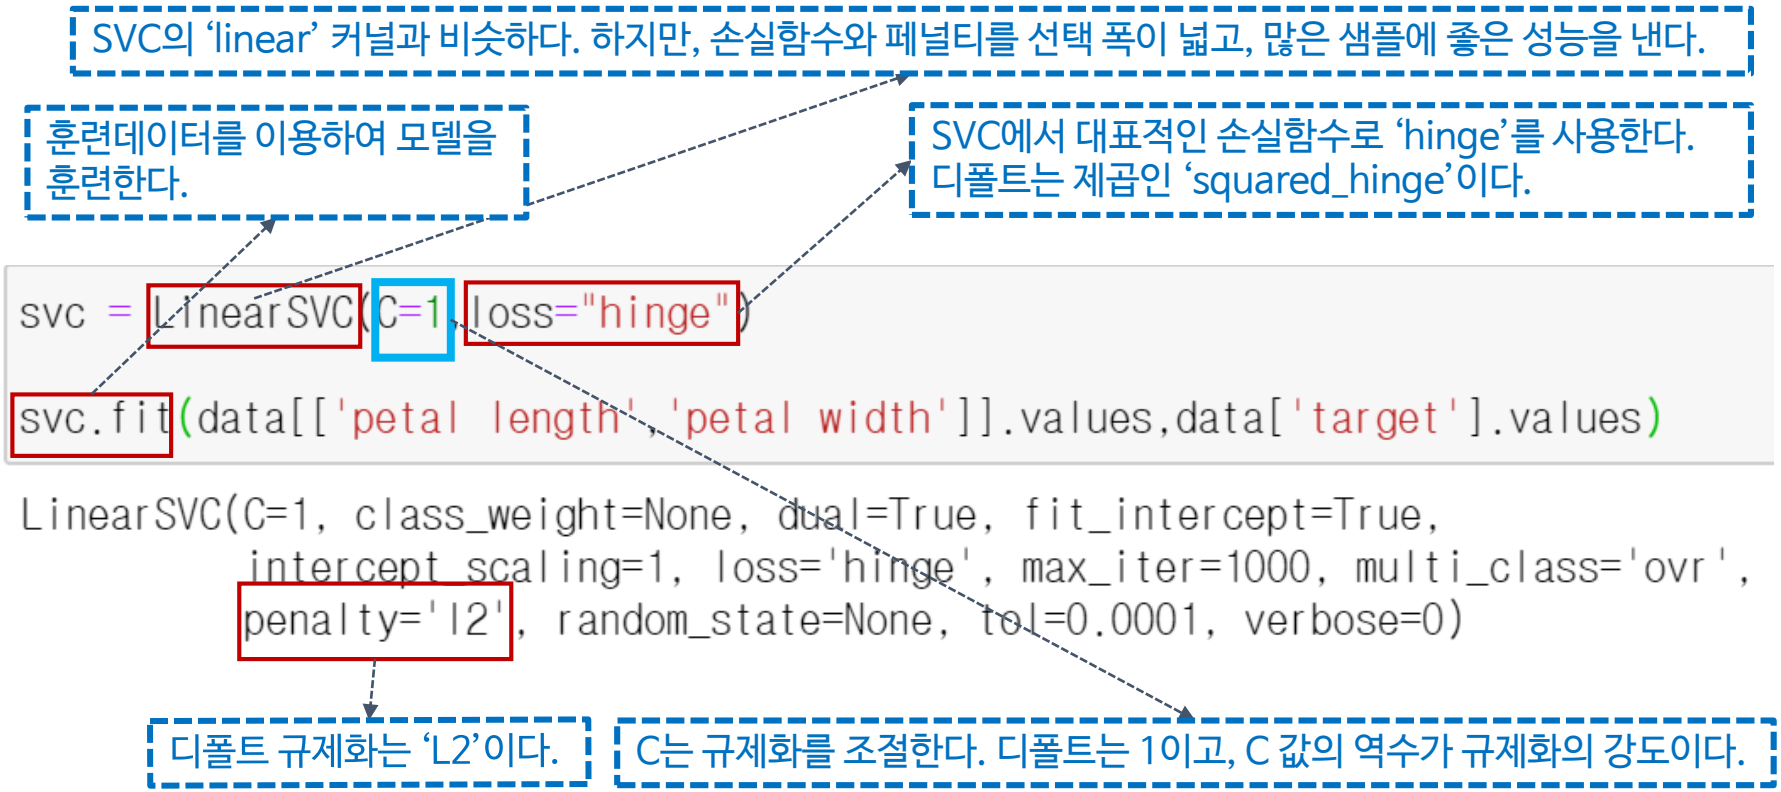

붓꽃에 LinearSVC 적용 (5)

```
# 그림을 그리기 위한 파라미터 설정
w0,w1 = svc.coef_[0]
b = svc.intercept_[0]
x0 = np.linspace(-1.7, 0.7, num=100)
x1_decision = -b/w1 - w0/w1*x0 # 결정경계
x1_plus = x1_decision + 1/w1   # +1 마진
x1_minus = x1_decision - 1/w1  # -1 마진
```

```
sns.lmplot(x='petal length',y='petal width',
           hue='target',data=data, fit_reg=False, legend=False)
plt.plot(x0,x1_decision, color='grey')
plt.plot(x0,x1_plus,x0,x1_minus,color='grey', linestyle='--')
plt.legend(['decision boundary','margin','margin','Setosa','Versicolor'],
           fontsize = 14, loc='center left', bbox_to_anchor=(1.05,0.5))
plt.xlabel('petal length (scaled)', fontsize = 18)
plt.ylabel('petal width (scaled)', fontsize = 18)
plt.title('[C = 1]', fontsize = 16)
plt.ylim(-1.6,1)
plt.xlim(-1.7,0.8)
plt.show()
```

붓꽃에 LinearSVC 적용 (6)

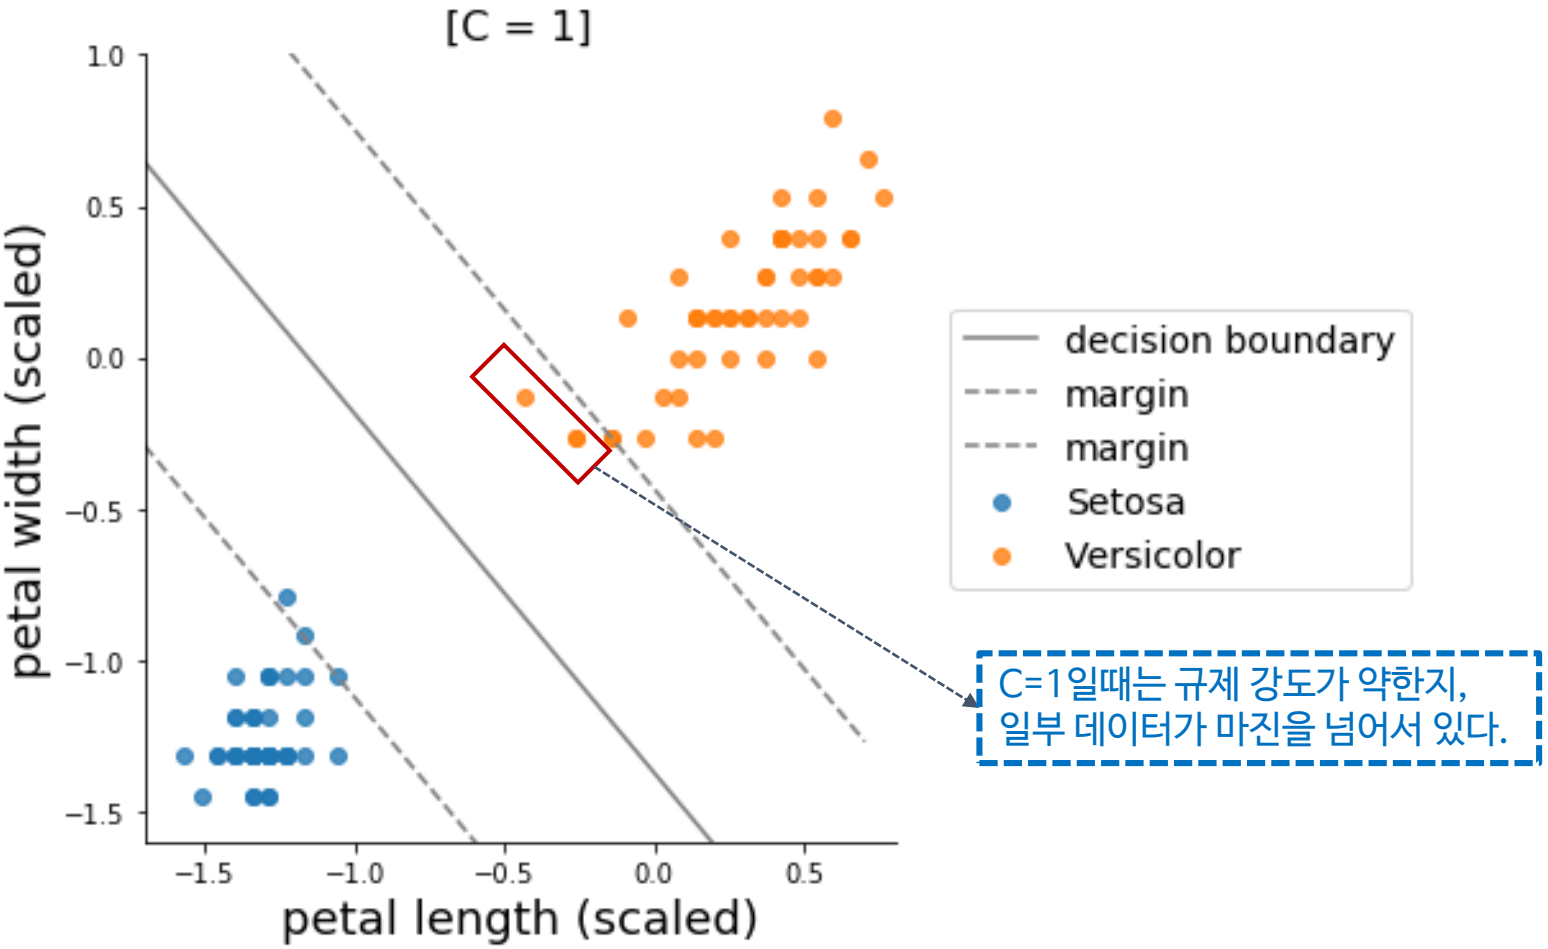

붓꽃에 LinearSVC 적용 (7)

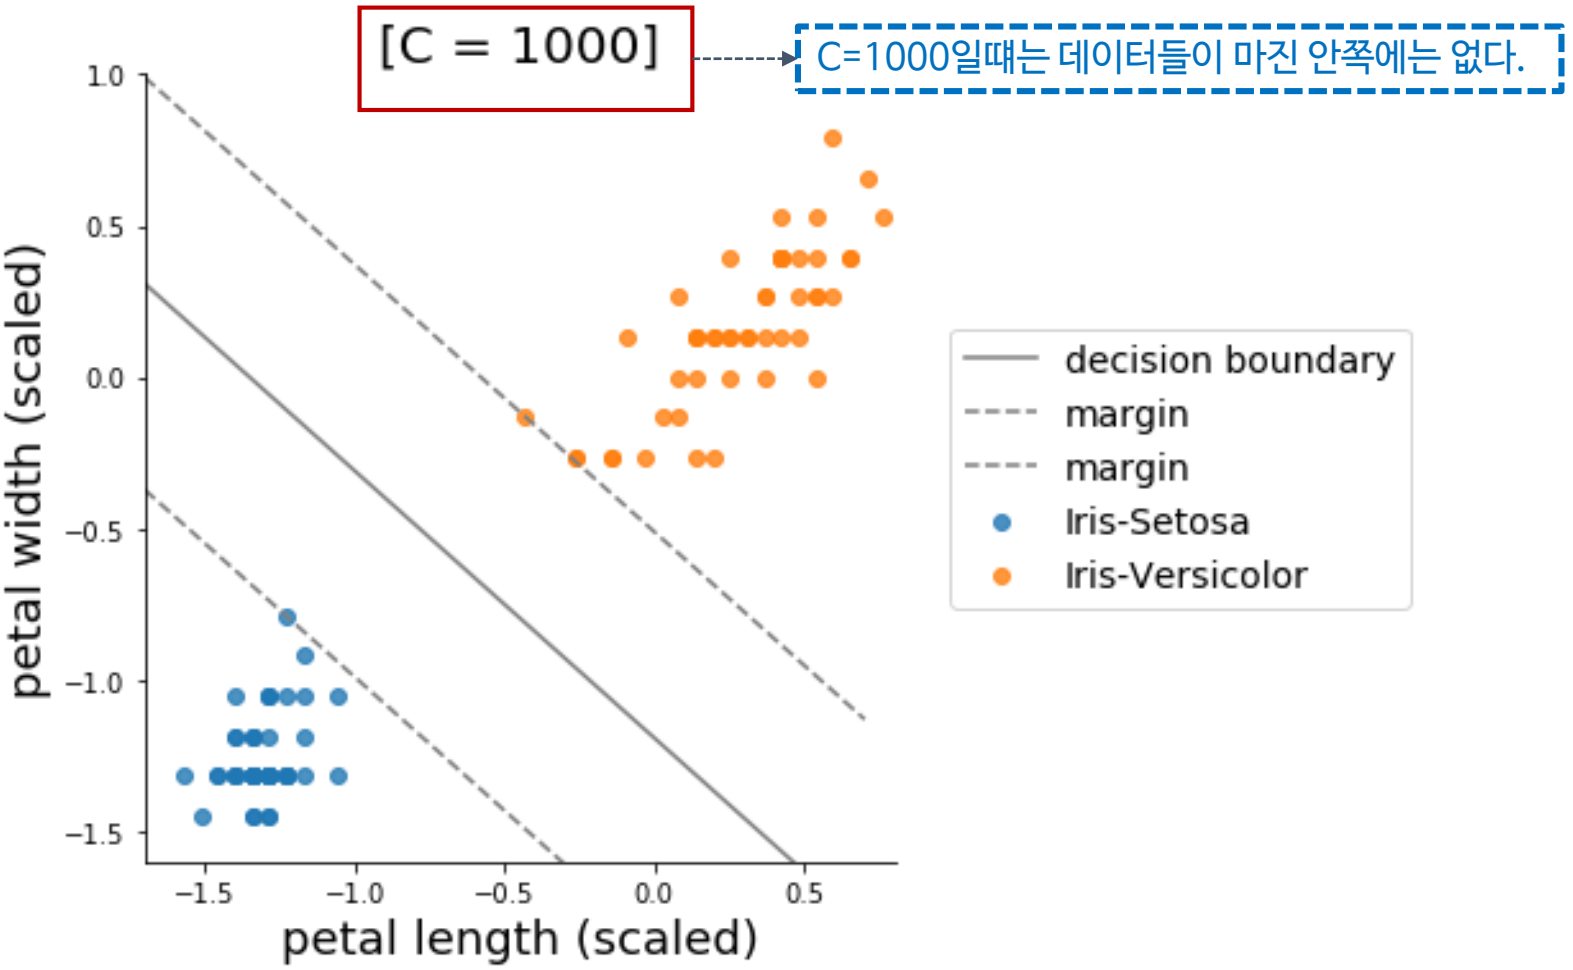

붓꽃에 SVM.SVC 적용하기 (1)

SVM의 커널 사용 ¶

#Modeling Different Kernel Svm classifier using Iris Sepal features

```
iris = datasets.load_iris()
X = iris.data[:, :2]  # 꽃받침
y = iris.target
C = 1.0
```

Sepal 꽃받침 길이, 너비를 사용하며,
IRIS 꽃 종류에 대한 제한은 없다. 3종류 모두 사용

```
lin_svc = svm.LinearSVC(C=C)
lin_svc.fit(X, y)
```

```
LinearSVC(C=1.0, class_weight=None, dual=True, fit_intercept=True,
          intercept_scaling=1, loss='squared_hinge', max_iter=1000,
          multi_class='ovr', penalty='l2', random_state=None, tol=0.0001,
          verbose=0)
```

붓꽃에 SVM.SVC 적용하기 (2)

Libsvm 라이브러리를 사용하며, 계산 시간은 크기의 3승이다. 따라서 1000개 이상 데이터에는 매우 긴 계산 시간을 요구하므로, 이 경우는 linearSVC 사용을 권장

```
svc = svm.SVC(kernel='linear', C=C)
svc.fit(X, y)
```

```
SVC(C=1.0, break_ties=False, cache_size=200, class_weight=None, coef0=0.0,
    decision_function_shape='ovr', degree=3, gamma='scale', kernel='linear',
    max_iter=-1, probability=False, random_state=None, shrinking=True,
    tol=0.001, verbose=False)
```

SVC 커널은 'linear', 'poly', 'rbf', 'sigmoid', 'precomputed'에서 1개를 선택할 것

붓꽃에 SVM.SVC 적용하기 (3)

```
rbf_svc = svm.SVC(kernel='rbf', gamma=0.7, C=C)
rbf_svc.fit(X, y)
```

Rbf와 sigmoid에서 사용하며, gamma=scale(디폴트)

```
SVC(C=1.0, break_ties=False, cache_size=200, class_weight=None, coef0=0.0,
    decision_function_shape='ovr', degree=3, gamma=0.7, kernel='rbf',
    max_iter=-1, probability=False, random_state=None, shrinking=True,
    tol=0.001, verbose=False)
```

```
poly_svc = svm.SVC(kernel='poly', degree=3, C=C)
poly_svc.fit(X, y)
```

폴리노미얼 커널 함수의 계수이며, 디폴트는 degree=3이다.

```
SVC(C=1.0, break_ties=False, cache_size=200, class_weight=None, coef0=0.0,
    decision_function_shape='ovr', degree=3, gamma='scale', kernel='poly',
    max_iter=-1, probability=False, random_state=None, shrinking=True,
    tol=0.001, verbose=False)
```

붓꽃에 SVM.SVC 적용하기 (4)

Visualizing the modeled svm classifiers with Iris Sepal features

```
h = .02  # step size in the mesh

x_min, x_max = X[:, 0].min() - 1, X[:, 0].max() + 1
y_min, y_max = X[:, 1].min() - 1, X[:, 1].max() + 1
xx, yy = np.meshgrid(np.arange(x_min, x_max, h),np.arange(y_min, y_max, h))
titles = ['SVC with linear kernel','LinearSVC (linear kernel)',
          'SVC with RBF kernel','SVC with polynomial (degree 3) kernel']
plt.figure(figsize=(16,16))
```

붓꽃에 SVM.SVC 적용하기 (5)

```
for i, clf in enumerate((svc, lin_svc, rbf_svc, poly_svc)):
    # Plot the decision boundary. For that, we will assign a color to each
    # point in the mesh [x_min, x_max]x[y_min, y_max].
    plt.subplot(2, 2, i + 1)
    plt.subplots_adjust(wspace=0.4, hspace=0.4)
    Z = clf.predict(np.c_[xx.ravel(), yy.ravel()])
    Z = Z.reshape(xx.shape)
    plt.contourf(xx, yy, Z, cmap=plt.cm.coolwarm, alpha=0.2)
    plt.scatter(X[:, 0], X[:, 1], c=y, cmap=plt.cm.coolwarm)
    plt.xlabel('Sepal length',fontsize = 18)
    plt.ylabel('Sepal width',fontsize = 18)
    plt.xlim(xx.min(), xx.max())
    plt.ylim(yy.min(), yy.max())
    plt.xticks(())
    plt.yticks(())
    plt.title(titles[i],fontsize = 18)

plt.show()
```

붓꽃에 SVM.SVC 적용하기 (6)

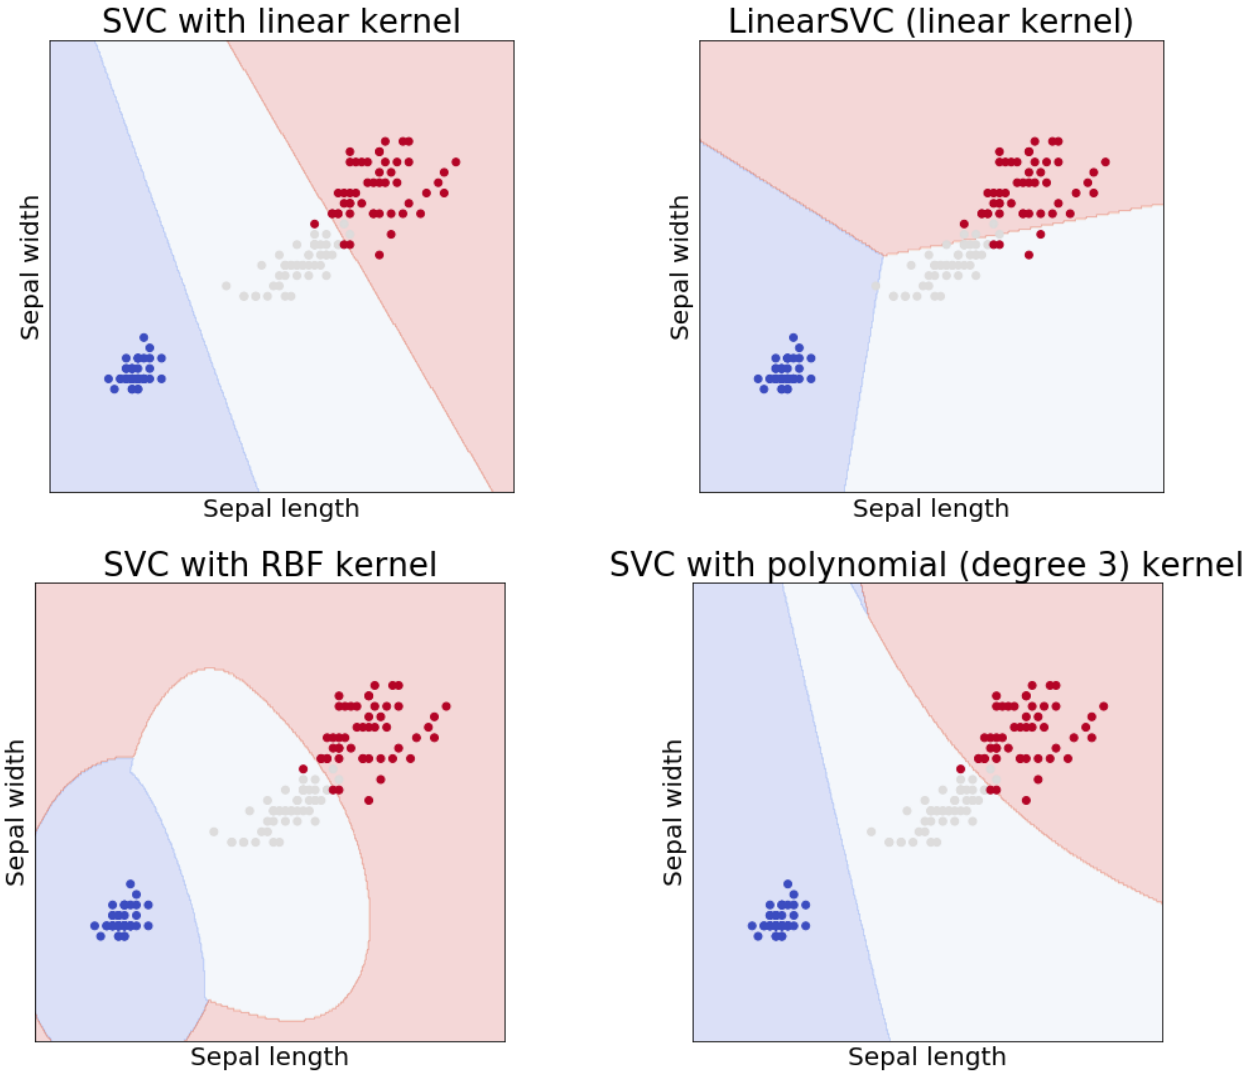

붓꽃에 SVM.SVC 적용하기 (7)

IRIS PETAL (꽃잎) 데이터를 SVM 4개의 다른 종류로 분류

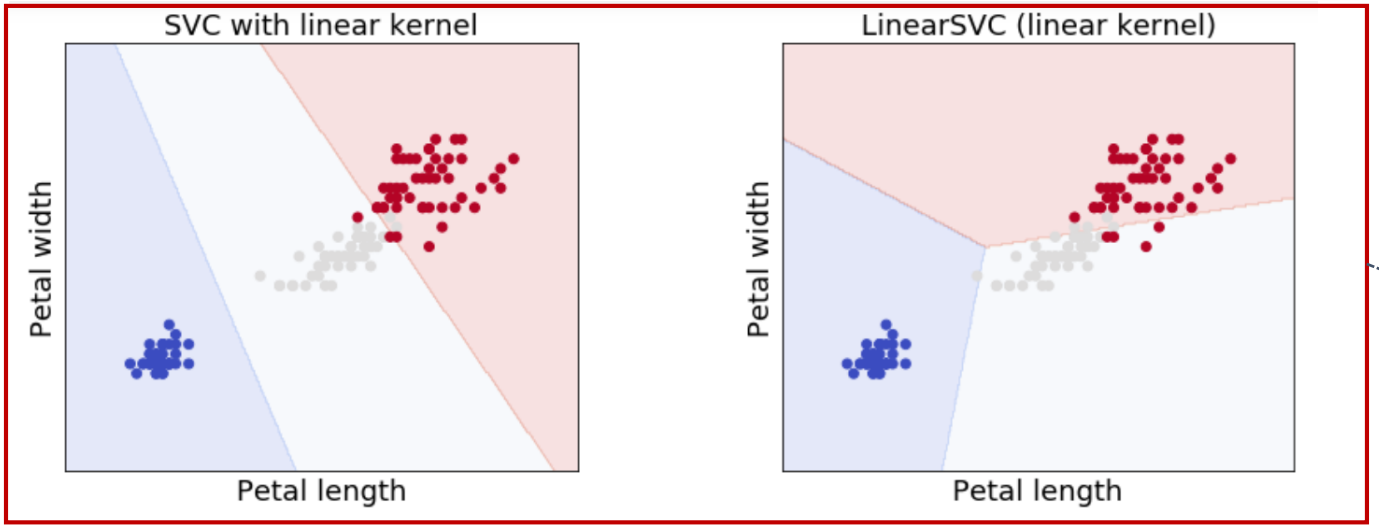

Linear 분류 성능을 비교하면, 어느 것이 더 우수한가?

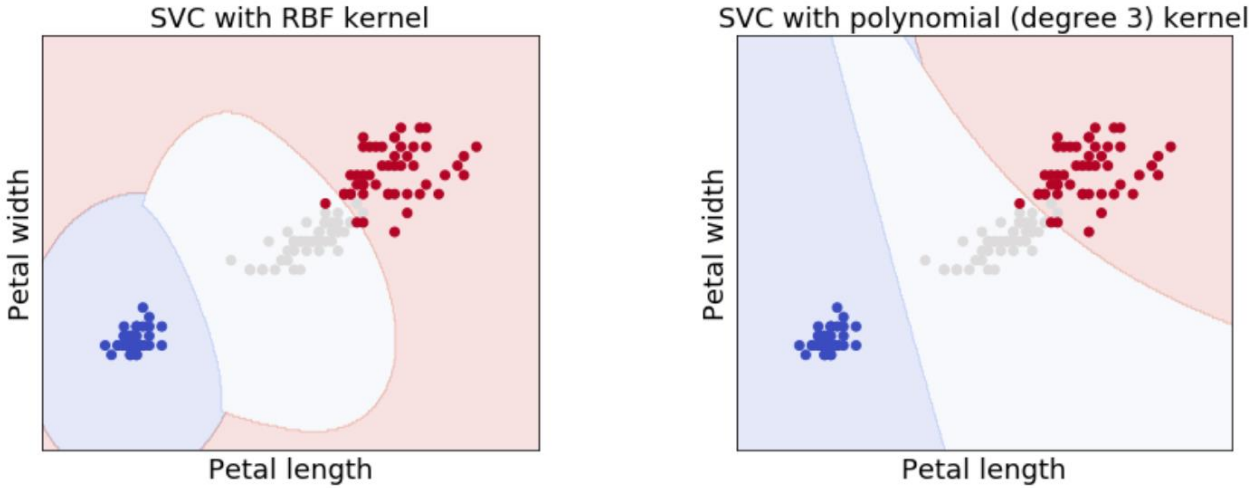

붓꽃에 SVM.SVC 적용하기 (8)

```
predictions = lin_svc.predict(iris.data[:, :2])
accuracy_score(predictions, iris.target)
```

Iris sepal 꽃받침

0.8

```
predictions = lin_svc.predict(iris.data[:, 2:])
```

Iris Petal 꽃잎의 경우

```
accuracy_score(predictions, iris.target)
```

0.94

```
from sklearn.model_selection import cross_val_score

scores = cross_val_score(lin_svc, iris.data, iris.target, cv=5)
print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(), scores.std() * 2))
```

Accuracy: 0.97 (+/- 0.08)

Petal(꽃잎) 데이터의 교차검증 성능은 97%로 매우 높다

비선형 SVM 적용 (1)

```
from sklearn.datasets import make_moons

X,y=make_moons(noise=0.1, random_state=2)

data = pd.DataFrame(data = X, columns=['x1','x2'])
data['y']=y
data.head()
```

초승달 모양의 데이터 생성

9]:

	x1	x2	y
0	1.327241	-0.222425	1
1	-0.429116	1.071136	0
2	0.014901	0.003679	1
3	0.000352	1.087226	0
4	0.676553	0.857039	0

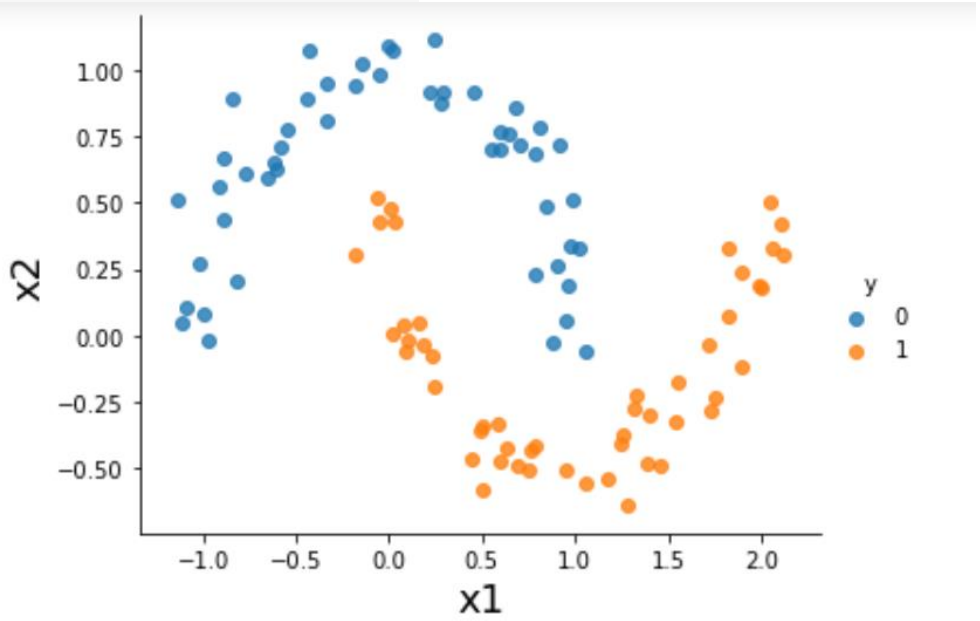

비선형 SVM 적용 (2)

```
# tranform the features, here we use a 3rd degree polynomials
print('Shape of X before tranformation:', X.shape)
poly = PolynomialFeatures(degree = 3, include_bias=False)
Xpoly = poly.fit_transform(X)
print('Shape of X aftere tranformation:', Xpoly.shape)
```

```
Shape of X before tranformation: (100, 2)
Shape of X aftere tranformation: (100, 9)
```

```
scaler = StandardScaler()
Xpolystan = scaler.fit_transform(Xpoly)

svm_clf = LinearSVC(C=10,loss='hinge',max_iter=10000)
svm_clf.fit(Xpolystan,y)
print(svm_clf.intercept_, svm_clf.coef_)
```

```
[0.14733125] [[-1.48192841 -0.38934979 -3.63169665 -0.24403263  0.84163192  6.20758509
  -0.98197827  0.70828887 -1.94865339]]
```

비선형 SVM 적용 (3)

```
# preparing to plot decision boundary of the classifier
def make_meshgrid(x, y, h=.02):
    x_min, x_max = x.min() - 1, x.max() + 1
    y_min, y_max = y.min() - 1, y.max() + 1
    xx, yy = np.meshgrid(np.arange(x_min, x_max, h),
                         np.arange(y_min, y_max, h))
    return xx, yy
```

```
X0, X1 = X[:, 0], X[:, 1]
xx0, xx1 = make_meshgrid(X0, X1)
# polynomial transformation and standardization on the grids
xgrid = np.c_[xx0.ravel(), xx1.ravel()]
xgridpoly = poly.transform(xgrid)
xgridpolystan = scaler.transform(xgridpoly)
# prediction
Z = xgridpolystan.dot(svm_clf.coef_[0].reshape(-1,1)) + svm_clf.intercept_[0] # wx + b
#Z = svm_clf.predict(xgridpolystan)
Z = Z.reshape(xx0.shape)
```

비선형 SVM 적용 (4)

```
# plotting prediction contours - decision boundary (Z=0), and two margins (Z = 1 or -1)
sns.lmplot(x='x1',y='x2',hue='y',data=data,
           fit_reg=False, legend=True, size=4, aspect=4/3)

CS=plt.contour(xx0, xx1, Z, alpha=0.5, levels=[-1,0,1])

#plt.clabel(CS, inline=1,levels=[-1.0,0,1.0], fmt='%1.1f',
plt.clabel(CS, inline=1,fmt='%1.1f',
           fontsize=12, manual=[(1.5,0.3),(0.5,0.0),(-0.5,-0.2)])

#
plt.xlim(-1.2,2.2)
plt.ylim(-1,1.5)
plt.title('C=10', fontsize = 20)
plt.xlabel('x1', fontsize = 18)
plt.ylabel('x2', fontsize = 18)
plt.show()
```

비선형 SVM 적용 (5)

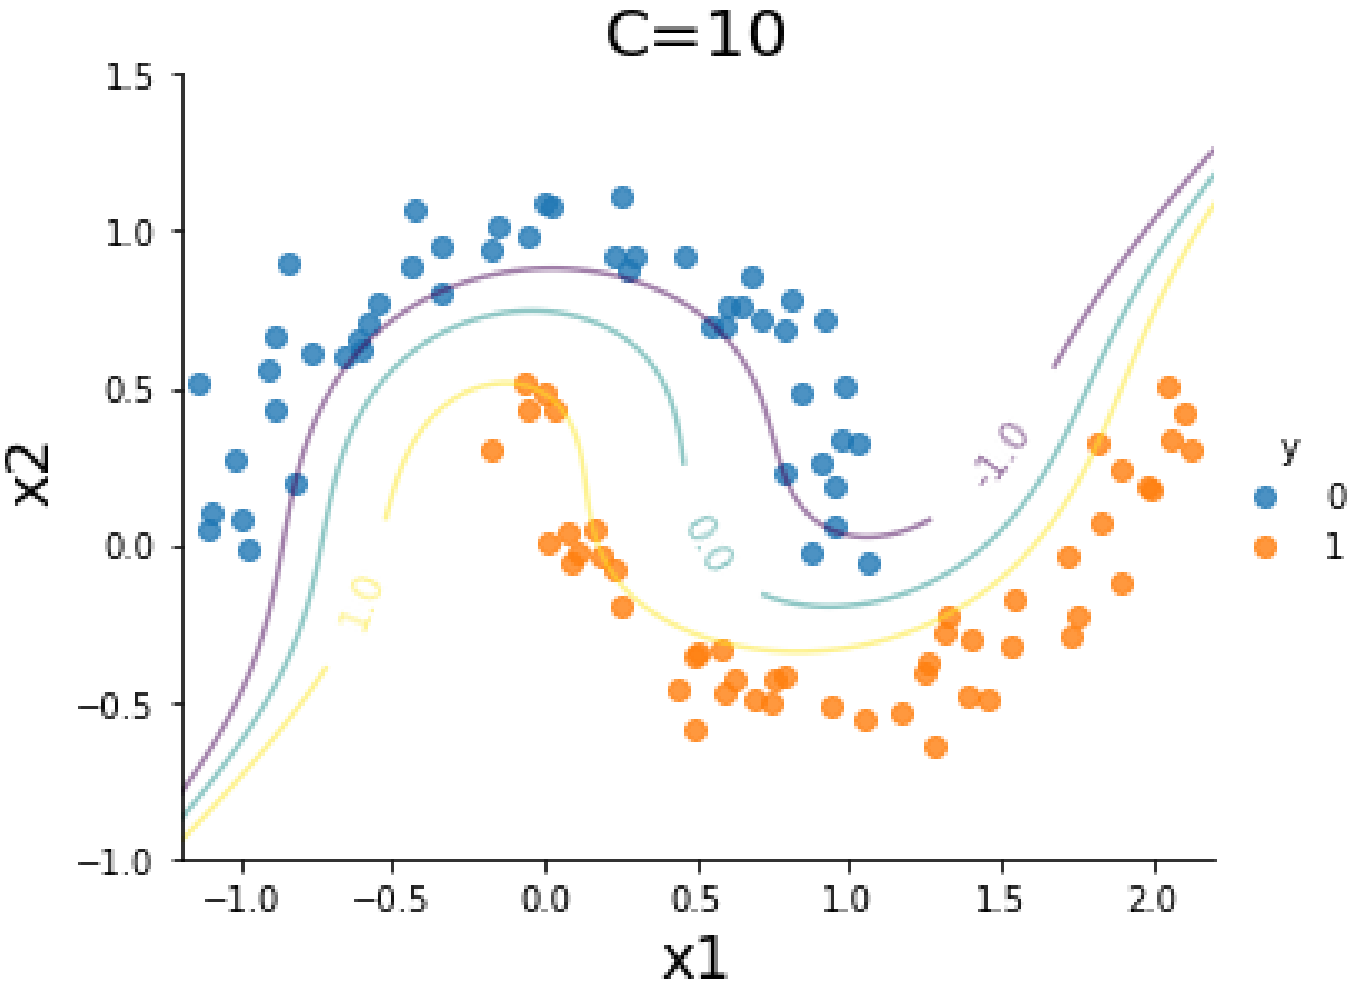

비선형 SVM 적용 (6)

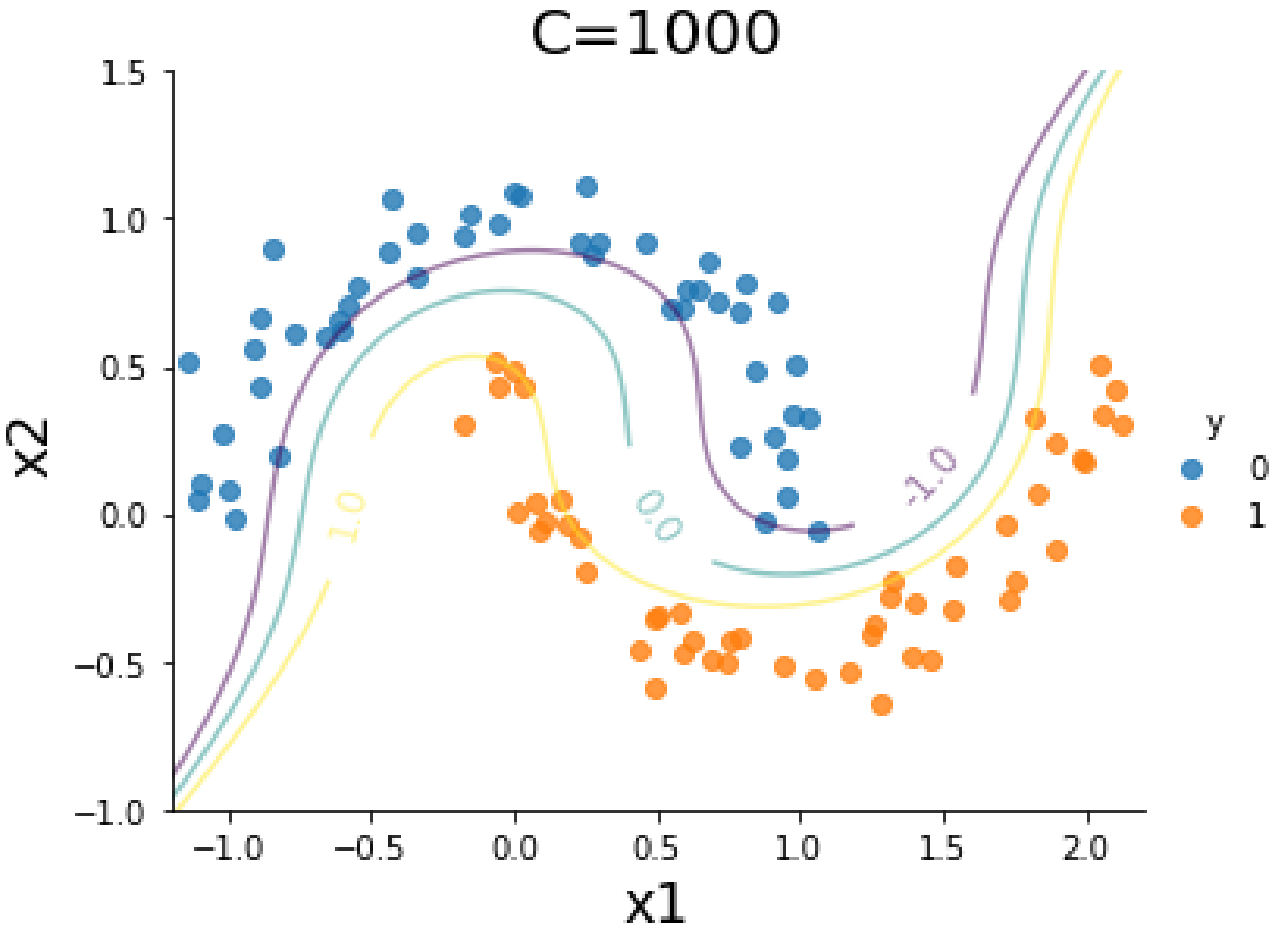

비선형 SVM 적용 (7)

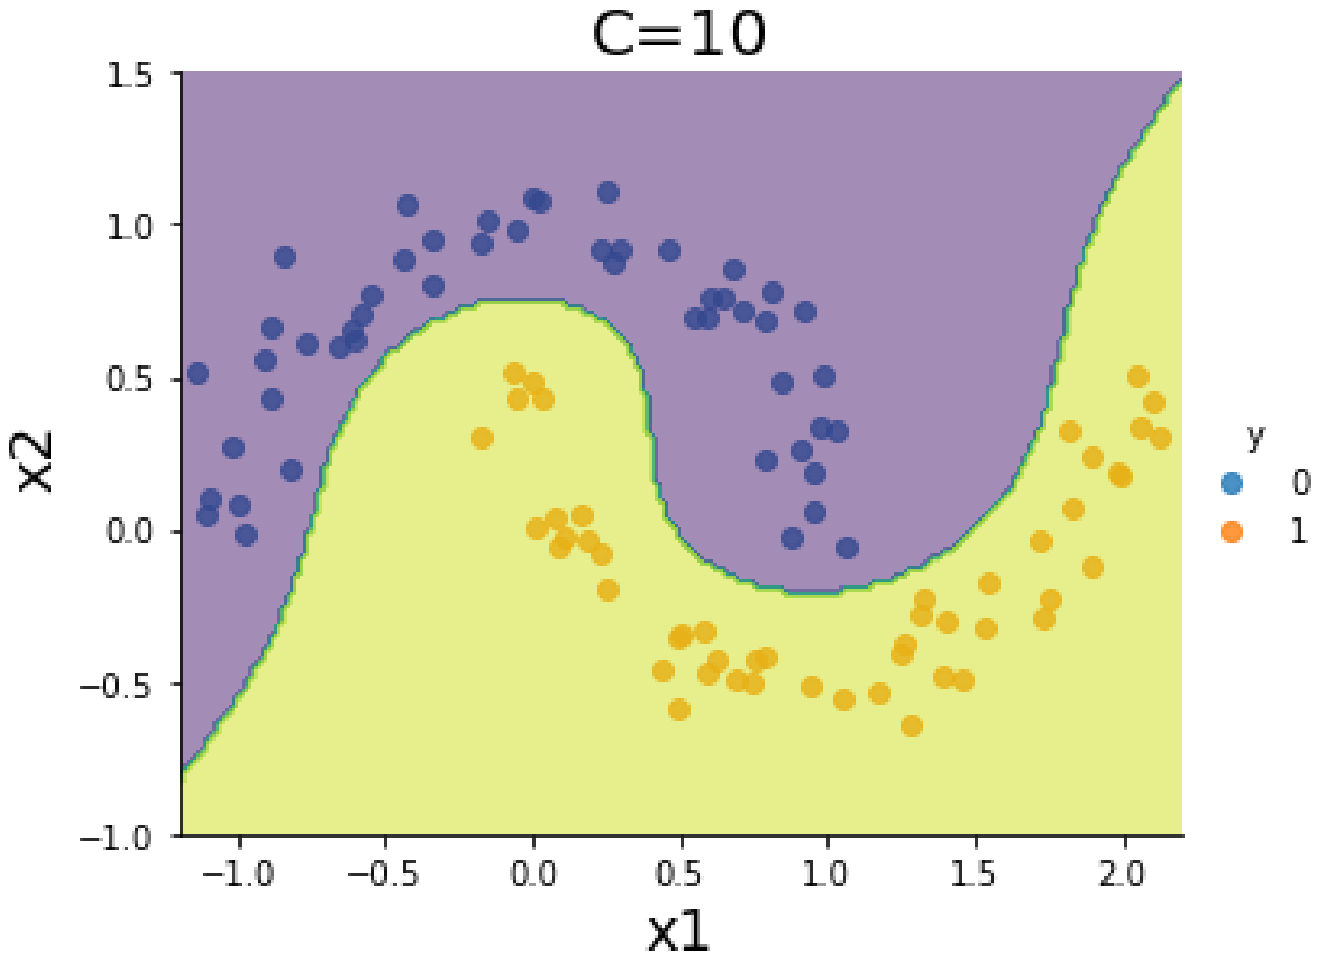

SVM을 심장질병 데이터에 적용(1)

실습05. SVM 적용을 위해 심장병 데이터를 이용하기

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

%matplotlib inline
sns.set_palette('Set1')
```

1) Reading Dataset

```
data = pd.read_csv('./input/heart.csv')
data.head()
```

SVM을 심장질병 데이터에 적용(2)

Reading Dataset

```
data = pd.read_csv('./input/heart.csv')
data.head()
```

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target
0	63	1	3	145	233	1	0	150	0	2.3	0	0	1	1
1	37	1	2	130	250	0	1	187	0	3.5	0	0	2	1
2	41	0	1	130	204	0	0	172	0	1.4	2	0	2	1
3	56	1	1	120	236	0	1	178	0	0.8	2	0	2	1
4	57	0	0	120	354	0	1	163	1	0.6	2	0	2	1

SVM을 심장질병 데이터에 적용(3)

1. age	나이 (int)
2. sex	성별 (1, 0 / int)
3. chest pain type (4 values)	가슴 통증 타입 (0 ~ 3 / int)
4. resting blood pressure	혈압
5. serum cholestoral in mg/dl	혈청 콜레스테롤
6. fasting blood sugar > 120 mg/dl	공복 혈당
7. resting electrocardiographic results	심전도
8. maximum heart rate achieved	최대 심장박동 수
9. exercise induced angina	운동 유도 협심증 (이게 뭐죠?)
10. oldpeak = ST depression induced by exercise relative to rest	노약 =운동에 의해 유발되는 St 우울증 (이건 또 뭐죠?)
11. the slope of the peak exercise ST segment	ST 세그먼트의 기울기
12. number of major vessels (0-3) colored by flourosopy	혈관의수
13. thal : 3 = normal; 6 = fixed defect; 7 = reversable defect	뭔지 모르겠네요

SVM을 심장질병 데이터에 적용(4)

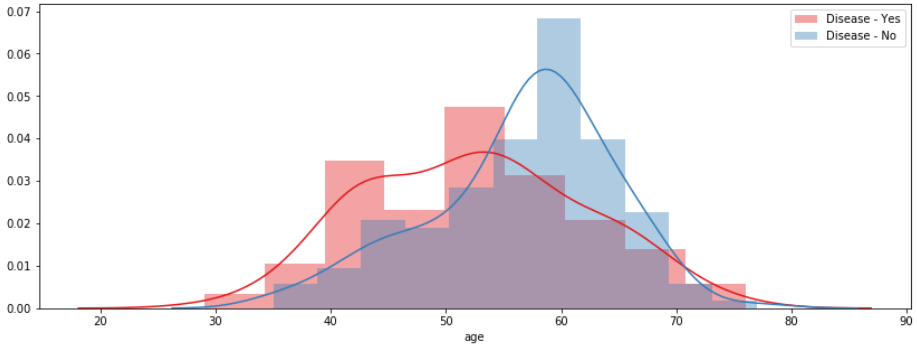

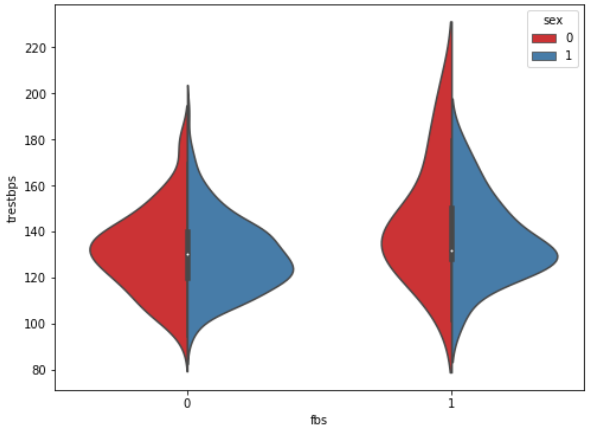

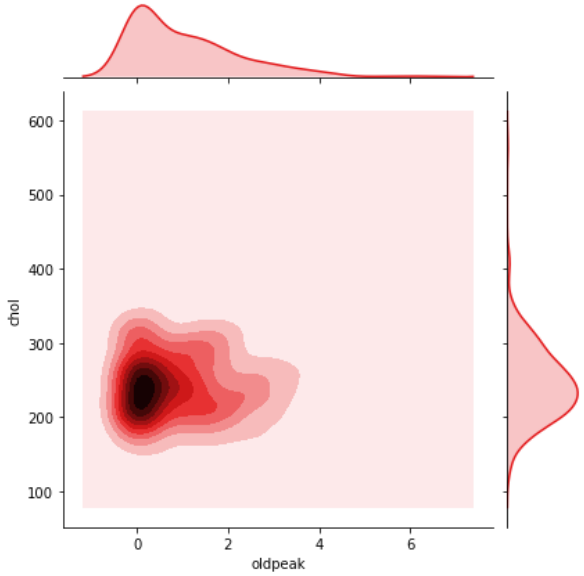

SVM을 심장질병 데이터에 적용(5)

Data Preprocessing ¶

- 카테로리컬 데이터를 변환하지

```
sex = pd.get_dummies(data['sex'])
cp = pd.get_dummies(data['cp'])
fbs = pd.get_dummies(data['fbs'])
restecg = pd.get_dummies(data['restecg'])
exang = pd.get_dummies(data['exang'])
slope = pd.get_dummies(data['slope'])
ca = pd.get_dummies(data['ca'])
thal = pd.get_dummies(data['thal'])
```

```
data = pd.concat([data, sex, cp, fbs, restecg, exang, slope, ca, thal], axis = 1)
```

SVM을 심장질병 데이터에 적용(6)

```
data.head()
```

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	...	2	0	1	2	3	4	0	1	2	3
0	63	1	3	145	233	1	0	150	0	2.3	...	0	1	0	0	0	0	0	1	0	0
1	37	1	2	130	250	0	1	187	0	3.5	...	0	1	0	0	0	0	0	0	1	0
2	41	0	1	130	204	0	0	172	0	1.4	...	1	1	0	0	0	0	0	0	1	0
3	56	1	1	120	236	0	1	178	0	0.8	...	1	1	0	0	0	0	0	0	1	0
4	57	0	0	120	354	0	1	163	1	0.6	...	1	1	0	0	0	0	0	0	1	0

5 rows × 39 columns

```
data.drop(['sex', 'cp', 'fbs', 'restecg', 'exang', 'slope', 'ca', 'thal'], axis = 1, inplace= True)
```

SVM을 심장질병 데이터에 적용(7)

4) Support Vector Machine (스케일 없이 그냥 해볼까?)

```
from sklearn.svm import SVC
model = SVC(probability=True)
from sklearn.model_selection import train_test_split

X = data.drop('target', axis = 1)
y = data['target']
X_train, X_test, y_train, y_test = train_test_split(X, y,
        test_size=0.3, random_state=42)
```

SVM을 심장질병 데이터에 적용(8)

```
model.fit(X_train, y_train)

y_pred = model.predict(X_test)

from sklearn.metrics import classification_report, accuracy_score, roc_curve, auc

print(classification_report(y_test, y_pred))
```

```
              precision    recall  f1-score   support

           0       0.78      0.44      0.56        41
           1       0.66      0.90      0.76        50

    accuracy                           0.69        91
   macro avg       0.72      0.67      0.66        91
weighted avg       0.72      0.69      0.67        91
```

SVM을 심장질병 데이터에 적용(9)

5) Support Vector Machine (스케일을 적용하자)

```
from sklearn.preprocessing import MinMaxScaler
scaler = MinMaxScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

model.fit(X_train, y_train)
y_pred = model.predict(X_test)
print(classification_report(y_test, y_pred))
```

```
              precision    recall  f1-score   support

           0       0.85      0.85      0.85        41
           1       0.88      0.88      0.88        50

    accuracy                           0.87        91
   macro avg       0.87      0.87      0.87        91
weighted avg       0.87      0.87      0.87        91
```

SVM을 심장질병 데이터에 적용(10)

```
y_prob = model.predict_proba(X_test)
fpr, tpr, thresholds = roc_curve(y_test, y_prob[:,1])
roc_auc = auc(fpr, tpr)
plt.title('Receiver Operating Characteristic')
plt.plot(fpr, tpr, 'b', label = 'AUC = %0.2f' % roc_auc)
plt.legend(loc = 'lower right')
plt.plot([0, 1], [0, 1],'r--')
plt.xlim([0, 1])
plt.ylim([0, 1])
plt.ylabel('True Positive Rate')
plt.xlabel('False Positive Rate')
plt.show()
```

SVM을 심장질병 데이터에 적용(11)

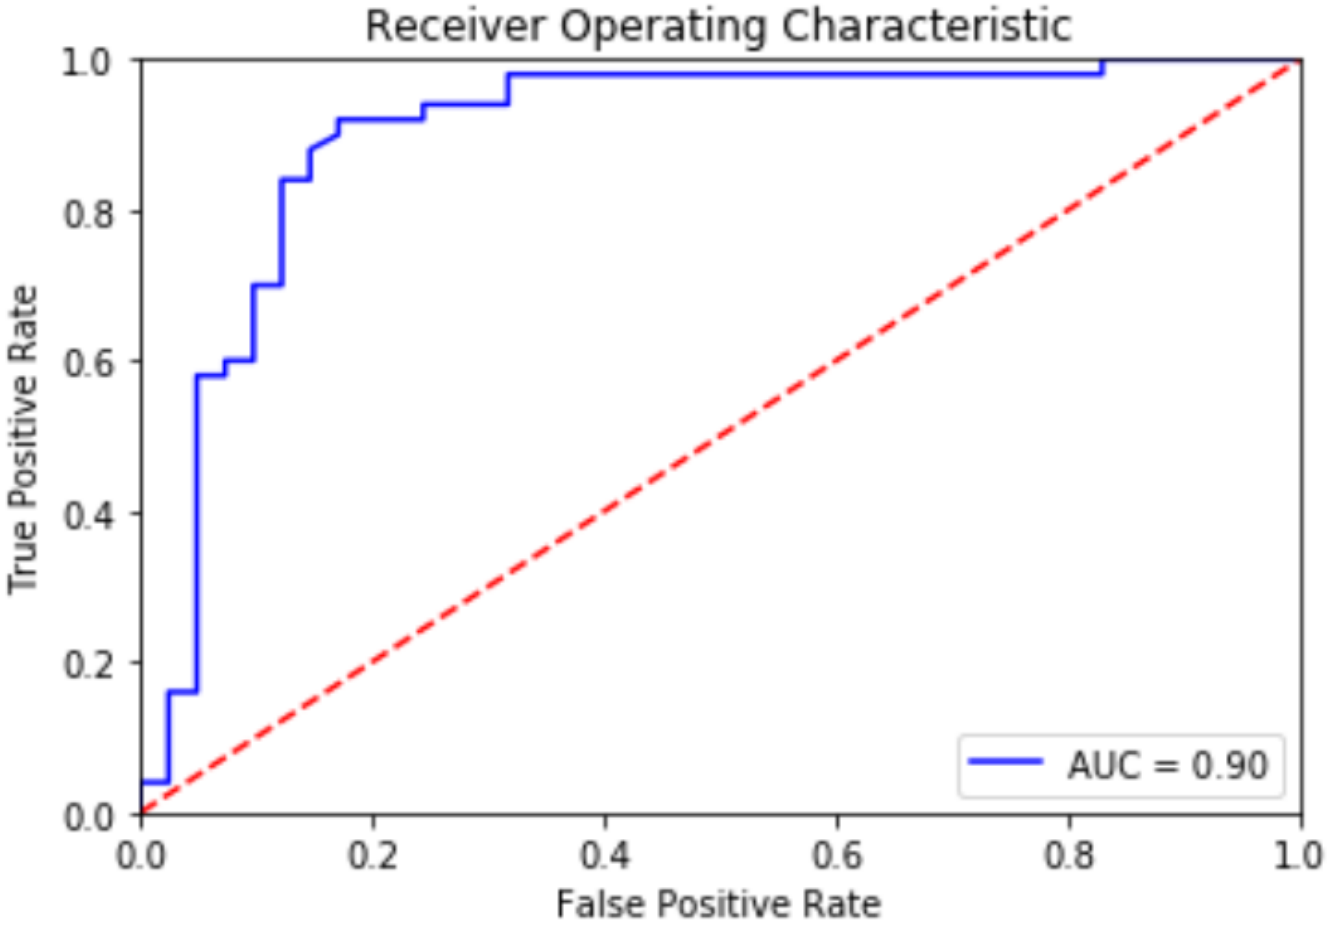

SVM을 심장질병 데이터에 적용(12)

디폴트 C=1

```
from sklearn.model_selection import learning_curve

train_sizes, train_scores, test_scores = learning_curve(SVC(), X_train,
    y_train, scoring='f1', train_sizes=np.linspace(0.1, 1.0, 20), cv = 3)

train_scores = np.mean(train_scores, axis = 1)
test_scores = np.mean(test_scores, axis = 1)

plt.plot(train_sizes, train_scores, 'o-', label="Training score")
plt.plot(train_sizes, test_scores, 'o-', label="Cross-validation score")
plt.legend();
```

SVM을 심장질병 데이터에 적용(13)

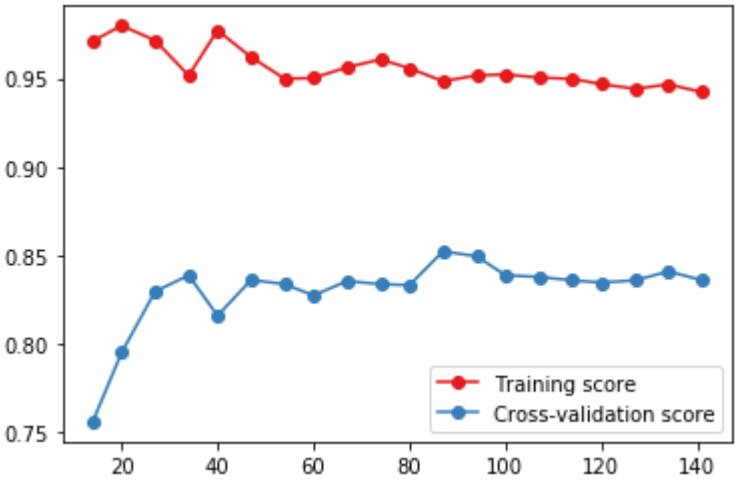


```
learning_curve(SVC(),
```

디폴트 값 사용
C=1

```
learning_curve(SVC(C=3, gamma=0.01)
```

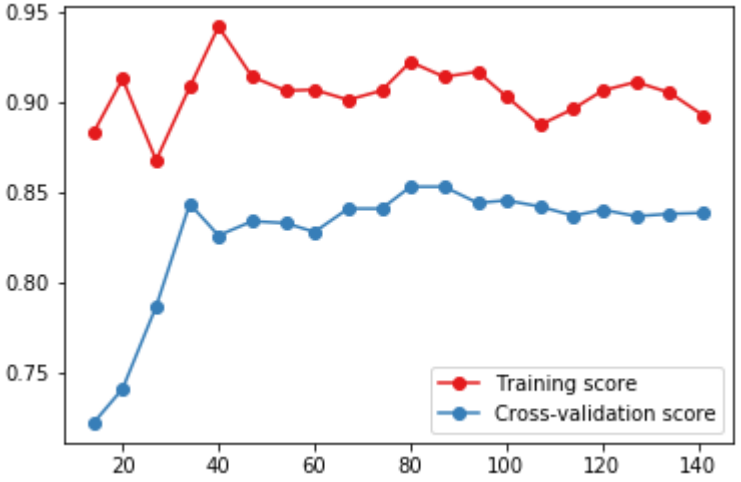

C=3,
Gamma=0.01

SVM을 심장질병 데이터에 적용(14)

- GridSearchCV

```
from sklearn.model_selection import GridSearchCV
param_grid = {'C':[1,2,3,4,5,6,7,8,14],
    'gamma':[0.1, 0.01, 0.001, 0.0001],
    'kernel':['linear', 'poly', 'rbf'],
    'degree': [1,2,3,4,5]}

grid = GridSearchCV(param_grid= param_grid, estimator= SVC(),
    scoring='f1', refit= True, verbose=1)
```

```
grid.fit(X_train, y_train)
grid.best_params_
```

```
Fitting 5 folds for each of 540 candidates, totalling 2700 fits

[Parallel(n_jobs=1)]: Using backend SequentialBackend with 1 concurrent workers.
[Parallel(n_jobs=1)]: Done 2700 out of 2700 | elapsed:    8.0s finished
```

46]: `{'C': 5, 'degree': 1, 'gamma': 0.1, 'kernel': 'poly'}`

SVM을 심장질병 데이터에 적용(15)

GridSearchCV를 자세히 파인튜닝을 해보면

```
param_grid = {'C':[6,7,8],
              'gamma':np.linspace(0.01, 0.02, 10),
              'kernel':['rbf'], 'degree': [1,2,3,4,5]}
grid = GridSearchCV(param_grid= param_grid, estimator= SVC(probability= True),
                    scoring='f1', refit= True, verbose=1)
grid.fit(X_train, y_train)
grid.best_params_
```

```
Fitting 5 folds for each of 150 candidates, totalling 750 fits
```

```
[Parallel(n_jobs=1)]: Using backend SequentialBackend with 1 concurrent workers.
[Parallel(n_jobs=1)]: Done 750 out of 750 | elapsed:    4.7s finished
```

```
{'C': 6, 'degree': 1, 'gamma': 0.01, 'kernel': 'rbf'}
```

SVM을 심장질병 데이터에 적용(16)

```
y_pred = grid.predict(X_test)
```

```
print(classification_report(y_test, y_pred))
```

```
              precision    recall  f1-score   support

           0       0.85      0.80      0.83        41
           1       0.85      0.88      0.86        50

    accuracy                           0.85        91
   macro avg       0.85      0.84      0.84        91
weighted avg       0.85      0.85      0.85        91
```

SVM을 심장질병 데이터에 적용(17)

```
y_prob = grid.predict_proba(X_test)

fpr, tpr, thresholds = roc_curve(y_test, y_prob[:,1])
roc_auc = auc(fpr, tpr)

plt.title('Receiver Operating Characteristic')
plt.plot(fpr, tpr, 'b', label = 'AUC = %0.2f' % roc_auc)
plt.legend(loc = 'lower right')
plt.plot([0, 1], [0, 1],'r--')
plt.xlim([0, 1])
plt.ylim([0, 1])
plt.ylabel('True Positive Rate')
plt.xlabel('False Positive Rate')
plt.show()
```

SVM을 심장질병 데이터에 적용(18)

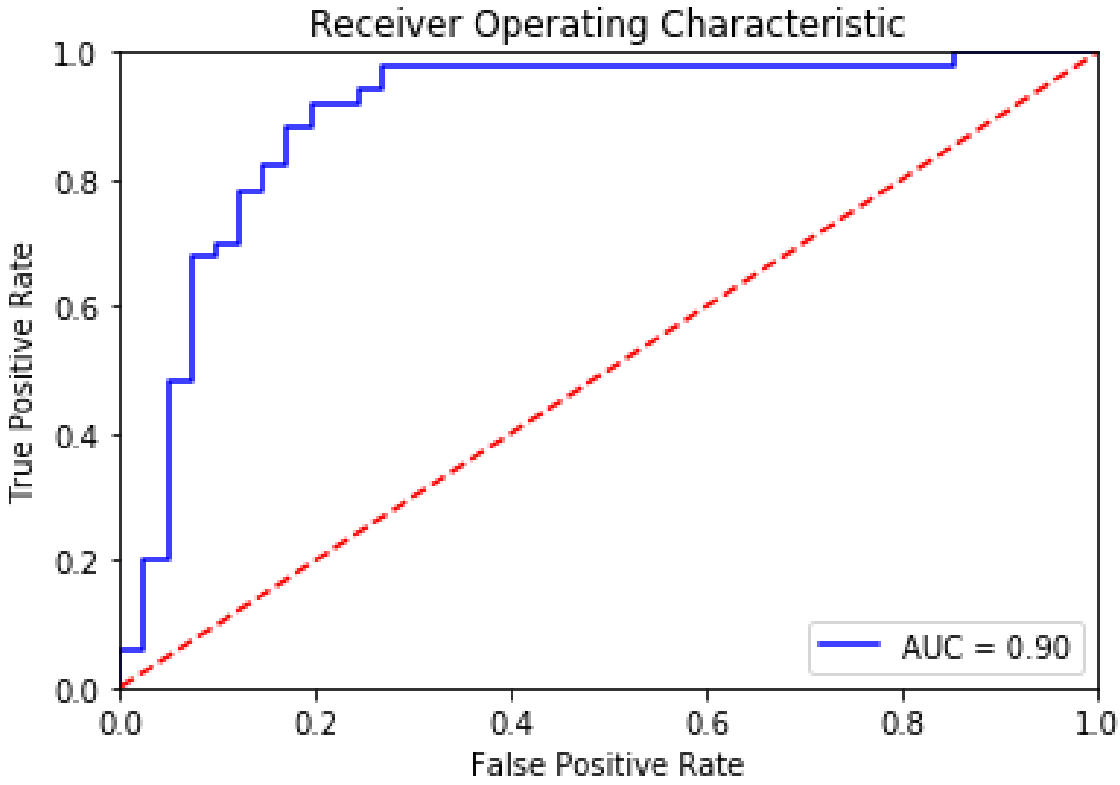


```
result = pd.DataFrame({'Test':y_test, 'Prediction':y_pred, 'Probability': y_prob[:,1]})
result.to_csv('Result.csv')
```

결과를 파일로 저장함

Thank You!

www.ust.ac.kr