UST 과학기술연합대학원대학교
UNIVERSITY OF SCIENCE & TECHNOLOGY

3강: 모델 성능 평가의 이해

인공지능 일반강좌 : 기계학습의 이해(L2-1)

Contents

Confusion Matrix 이해

- 임신테스트 예제로 임신이면 +(1), 아니면 –(0)
  - ✓ TP (True Positive) : 임신 했을 때, 테스트 결과는 1
  - ✓ TN (True Negative) : 임신은 안 했을 때 , 테스트 결과는 0
  - ✓ FP (False Positive) : 임신은 안 했을 때, 테스트 결과는 1 (에러)
  - ✓ FN (False Negative) : 임신 했는데, 테스트 결과는 0

성능 평가 (1)

- 분류문제는 회귀 분석과 달리 다양한 성능평가 기준이 필요하다.
  - ✓ 이 절에서는 분류문제에 사용되는 다양한 성능평가 기준에 대해 알아본다.
- 사이킷런 패키지에서 지원하는 분류 성능평가 명령
  - ✓ confusion_matrix(y_true, y_pred)
  - ✓ accuracy_score(y_true, y_pred)
  - ✓ precision_score(y_true, y_pred)
  - ✓ recall_score(y_true, y_pred)
  - ✓ fbeta_score(y_true, y_pred, beta)
  - ✓ f1_score(y_true, y_pred)
  - ✓ classfication_report(y_true, y_pred)
  - ✓ roc_curve
  - ✓ auc

혼동행렬 Confusion Matrix

- 혼동행렬
  - ✓ 타겟의 원래 클래스와 모형이 예측한 클래스가 일치하는지는 개수로 센 결과를 행렬로 나타낸 것
  - ✓ 정답 클래스는 행(row)으로 예측한 클래스는 열(column)로 나타낸다.

	예측 클래스	예측 클래스 1	예측 클래스 2
정답 클래스 0	정답 클래스가 0, 예측 클래스가 0인 표본의 수	정답 클래스가 0, 예측 클래스가 1인 표본의 수	정답 클래스가 0, 예측 클래스가 2인 표본의 수
정답 클래스 1	정답 클래스가 1, 예측 클래스가 0인 표본의 수	정답 클래스가 1, 예측 클래스가 1인 표본의 수	정답 클래스가 1, 예측 클래스가 2인 표본의 수
정답 클래스 2	정답 클래스가 2, 예측 클래스가 0인 표본의 수	정답 클래스가 2, 예측 클래스가 1인 표본의 수	정답 클래스가 2, 예측 클래스가 2인 표본의 수

혼동행렬 Confusion Matrix (1)

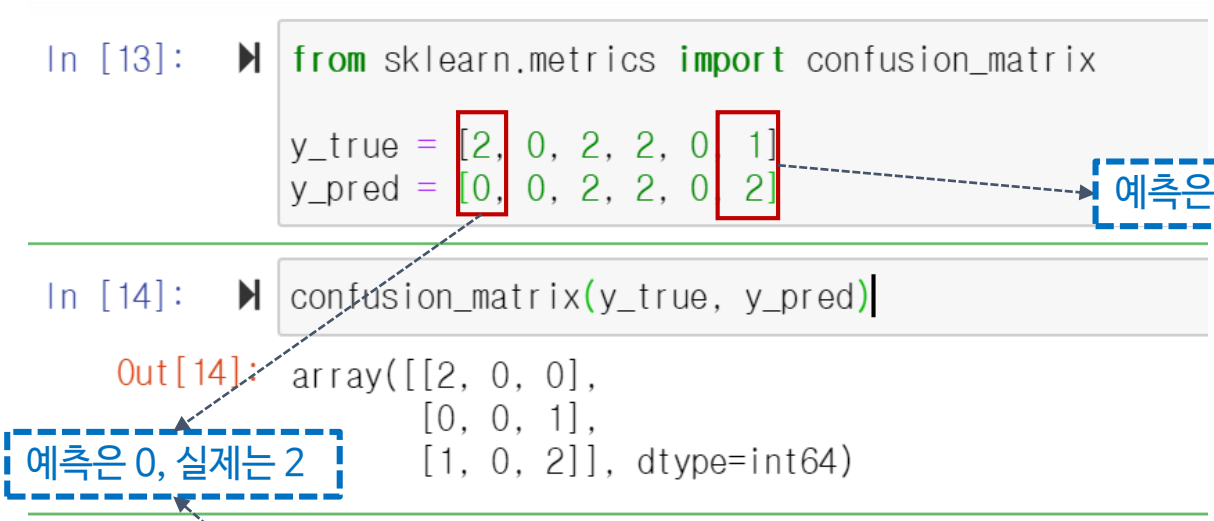

	예측 0	예측 1	예측 2
실제 0	2	0	0
실제 1	0	0	1
실제 2	1	0	2

혼동행렬 Confusion Matrix (2)

제품을 생산하는 공장에서는 완성된 제품에 대해 품질 테스트를 실시

- 불량품을 찾아내고 찾아낸 불량품은 공장으로 되돌린다(리콜, **recall**)
- 이 때 품질 테스트 결과가 양성이면 불량품이라고 예측한 것이고
- 음성이고 정상제품이라고 예측한 것
  - True Positive: 불량품을 불량품이라고 정확하게 예측
  - True Negative: 정상제품을 정상제품이라고 정확하게 예측
  - False Positive: 불량품을 정상제품이라고 잘못 예측
  - False Negative: 정상제품을 불량품이라고 잘못 예측

	불량품이라고 예측	**정상제품이라고 예측**
실제로 불량품	True Positive	False Negative
실제로 정상제품	False Positive	True Negative

	양성이라고 예측	**음성이라고 예측**
실제 양성	양성 예측이 맞음 (True Positive)	음성 예측이 틀림 (False Negative)
실제 음성	양성 예측이 틀림 (False Positive)	음성 예측이 맞음 (True Negative)

혼동행렬 Confusion Matrix (3)

- **예제) 암(cancer, 악성종양)을 검진**
  - ✓ **암에 걸린 것을 양성(陽性, positive)이라 함**
  - ✓ **걸리지 않은 것을 음성이라고 함.**
    - 종양(tumar)의 양성(良性, benign), 악성(惡性, malignant) 용어와 다르다는 점에 주의하라.
  - ✓ **True Positive: 암을 암이라고 정확하게 예측**
  - ✓ **True Negative: 암이 아닌것을 암이 아니라고 정확하게 예측**
  - ✓ **False Positive: 암을 암이 아니라고 잘못 예측**
  - ✓ **False Negative: 암이 아닌것을 암이라고 잘못 예측**

	암이라고 예측	암이 아니라고 예측
실제로 암	True Positive	False Negative
실제로 암이 아님	False Positive	True Negative

혼동행렬 Confusion Matrix (4)

- FDS(Fraud Detection System)
  - ✓ 금융 거래, 회계 장부 등에서 잘못된 거래, 사기거래를 찾아내는 시스템
  - ✓ FDS의 예측 결과가 양성이면 사기거래라고 예측
  - ✓ 음성이면 정상거래라고 예측
    - True Positive: 사기를 사기라고 정확하게 예측
    - True Negative: 정상을 정상이라고 정확하게 예측
    - False Positive: 정상을 사기라고 잘못 예측
    - False Negative: 사기를 정상이라고 잘못 예측

	사기라고 예측	정상이라고 예측
실제로 사기	True Positive	False Negative
실제로 정상	False Positive	True Negative

혼동행렬 Confusion Matrix (5)

```
from sklearn.metrics import classification_report

y_true = [0, 0, 0, 1, 1, 0, 0]
y_pred = [0, 0, 0, 0, 1, 1, 1]

print(classification_report(y_true, y_pred, target_names=['class 0', 'class 1']))
```

실제 0인 데이터 중의 60%만 0으로 판별되었고,
실제 1인 데이터 중의 50%만 1로 판별되었음을 알 수 있다

	precision	recall	f1-score	support
class 0	0.75	0.60	0.67	5
class 1	0.33	0.50	0.40	2
accuracy			0.57	7
macro avg	0.54	0.55	0.53	7
weighted avg	0.63	0.57	0.59	7

- macro: 단순평균
- weighted: 각 클래스에 속하는 표본의 갯수로 가중평균
- accuracy: 정확도. 전체 학습데이터의 개수에서 각 클래스에서 자신의 클래스를 정확하게 맞춘 개수의 비율

결과에서 0이라고 예측한 데이터의 75%만 실제로 0이었고 1이라고 예측한 데이터의 33%만 실제로 1이다.

혼동행렬 Confusion Matrix (6)

	예측 클래스 0	예측 클래스 1	예측 클래스 2
정답 클래스 0	TP	FP/FN	FP/FN
정답 클래스 1	FP/FN	TP	FP/FN
정답 클래스 2	FP/FN	FP/FN	TP

```
y_true = [0, 0, 1, 1, 2, 2, 2]
y_pred = [0, 0, 1, 2, 2, 2, 1]
target_names = ['class 0', 'class 1', 'class 2']
print(classification_report(y_true, y_pred, target_names=target_names))
```

```
              precision    recall  f1-score   support

     class 0       1.00      1.00      1.00         2
     class 1       0.50      0.50      0.50         2
     class 2       0.67      0.67      0.67         3

    accuracy                           0.71         7
   macro avg       0.72      0.72      0.72         7
weighted avg       0.71      0.71      0.71         7
```

ROC 커브 (1)

- ROC(Receiver Operator Characteristic) 커브는
  - ✓ 재현율(recall)과 위양성률(fall-out)은 일반적으로 양의 상관 관계가 있다.
  - ✓ 재현율을 높이기 위해서는 양성으로 판단하는 기준(threshold)을 낮추어 약간의 증거만 있어도 양성으로 판단하도록 하면 된다.
  - ✓ 그러나 이렇게 되면 음성임에도 양성으로 판단되는 표본 데이터가 같이 증가하게 되어 위양성율이 동시에 증가한다.
  - ✓ 반대로 위양성율을 낮추기 위해 양성을 판단하는 기준을 엄격하게 두게 되면 증거 부족으로 음성 판단을 받는 표본 데이터의 수가 같이 증가하므로 재현율이 떨어짐

ROC 커브 (2)

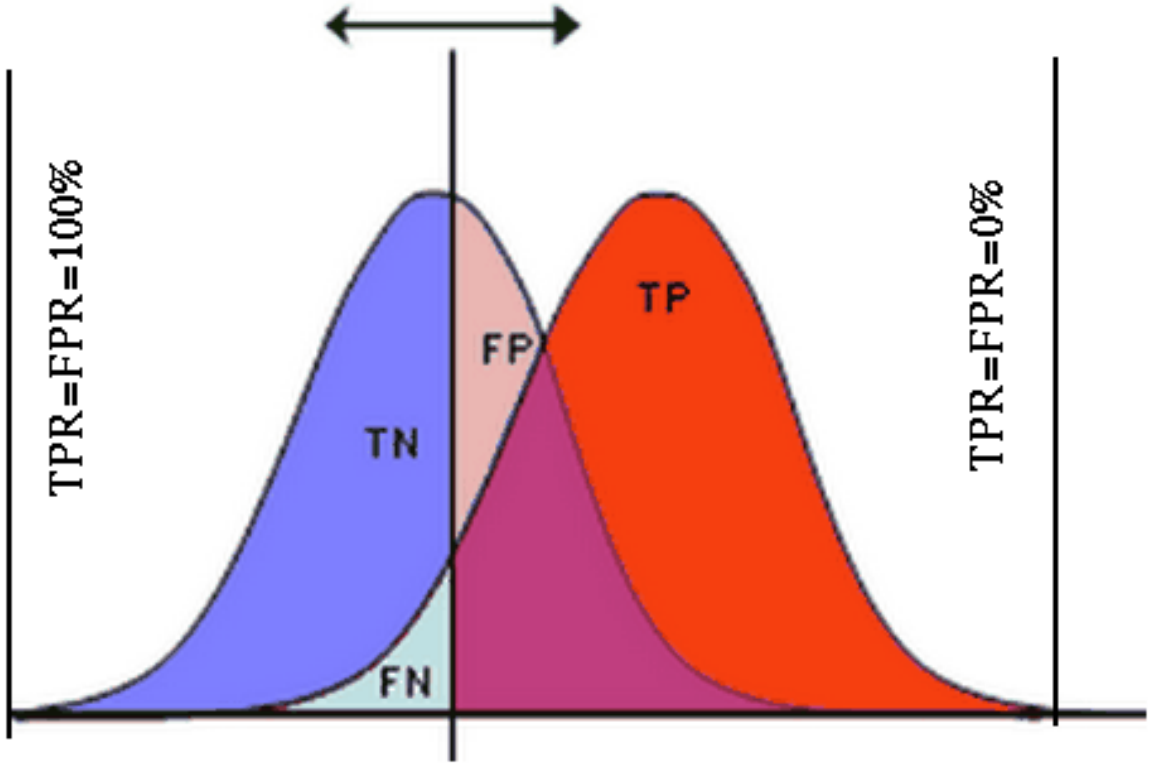

ROC 커브 (3)

- **판별함수 (discriminant function)**
  - ✓ **모든 이진 분류 모형은 판별 평면으로부터의 거리에 해당하는 판별함수를 가지며**
  - ✓ **판별함수값이 음수이면 0인 클래스, 양수이면 1인 클래스에 해당한다고 판별**
    - ROC 커브는 이 클래스 판별 기준 값이 달라진다면 결과가 어떻게 달라짐을 표현

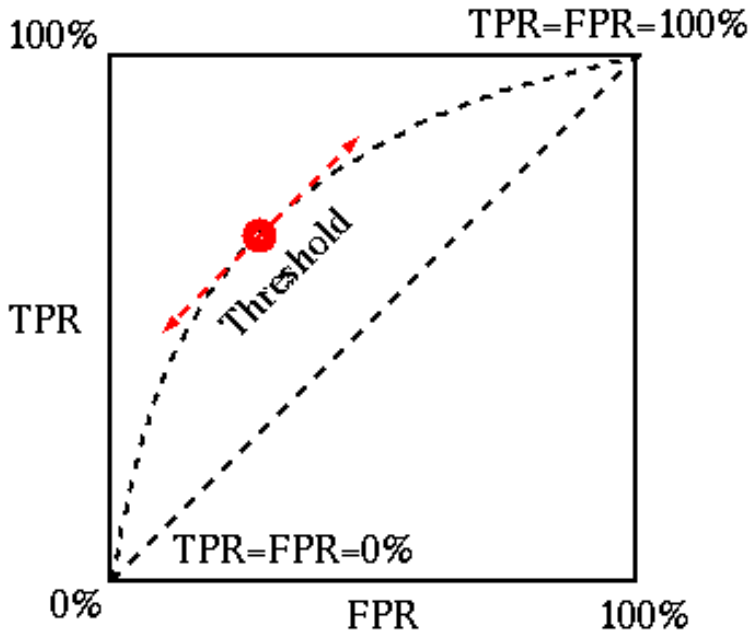

ROC 커브 (4)

```
import pandas as pd
import numpy as np
import matplotlib as plt
```

```
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression

X, y = make_classification(n_samples=16, n_features=2,
                           n_informative=2, n_redundant=0,
                           random_state=0)

model = LogisticRegression().fit(X, y)
y_hat = model.predict(X)
f_value = model.decision_function(X)
```

ROC 커브 (5)

```
df = pd.DataFrame(np.vstack([f_value, y_hat, y]).T, columns=["f", "y_hat", "y"])
df.sort_values("f", ascending=False).reset_index(drop=True)
```

	f	y_hat	y
0	2.363163	1.0	1.0
1	2.065047	1.0	1.0
2	1.633657	1.0	1.0
3	1.626171	1.0	1.0
4	1.624967	1.0	1.0
5	1.219678	1.0	1.0
6	0.378296	1.0	0.0
7	0.094285	1.0	1.0
8	-0.438666	0.0	0.0
9	-0.765888	0.0	0.0
10	-0.926932	0.0	1.0
11	-1.046770	0.0	0.0
12	-1.214700	0.0	0.0
13	-1.429382	0.0	0.0
14	-2.081586	0.0	0.0
15	-4.118969	0.0	0.0

ROC 커브 (6)

- ROC 커브는 현재는 0을 기준값(threshold)으로 클래스를 구분하여, 값이 0보다 크면 양성, 작으면 음성
- 데이터 분류가 다르게 되도록 기준값을 증가 혹은 감소시킨다. 위의 표에서는 기준값을 0.244729보다 크도록 올리면 6번 데이터는 더이상 양성이 아니다.
- 기준값을 여러가지 방법으로 증가 혹은 감소시키면서 이를 반복하면 여러가지 다른 기준값에 대해 분류 결과가 달라지고 재현율, 위양성률 등의 성능평가 점수도 달라진다.
- 기준값 0을 사용하여 이진 분류결과표, 재현율, 위양성율을 계산하면 다음과 같다.

```
confusion_matrix(y, y_hat, labels=[1, 0])
```

```
]: array([[7, 1],
          [1, 7]], dtype=int64)
```

```
recall = 6 / (6 + 2)
fallout = 1 / (1 + 7)
print("recall =", recall)
print("fallout =", fallout)
```

```
recall = 0.75
fallout = 0.125
```

ROC 커브 (7)

```
from sklearn.metrics import roc_curve

fpr, tpr, thresholds = roc_curve(y, model.decision_function(X))
fpr, tpr, thresholds
```

```
(array([0.   , 0.   , 0.   , 0.125, 0.125, 0.375, 0.375, 1.   ]),
 array([0.   , 0.125, 0.75 , 0.75 , 0.875, 0.875, 1.   , 1.   ]),
 array([ 3.36316277,  2.36316277,  1.21967832,  0.37829565,  0.09428499,
        -0.76588836, -0.92693183, -4.11896895]))
```

decision_function 메서드를 제공하지 않는 모형은 predict_proba 명령을 써서 확률을 입력

```
fpr, tpr, thresholds = roc_curve(y, model.predict_proba(X)[:, 1])
fpr, tpr, thresholds
```

```
(array([0.   , 0.   , 0.   , 0.125, 0.125, 0.375, 0.375, 1.   ]),
 array([0.   , 0.125, 0.75 , 0.75 , 0.875, 0.875, 1.   , 1.   ]),
 array([1.9139748 , 0.9139748 , 0.77200693, 0.59346197, 0.5235538 ,
        0.31736921, 0.28354759, 0.01600107]))
```

ROC 커브 (8)

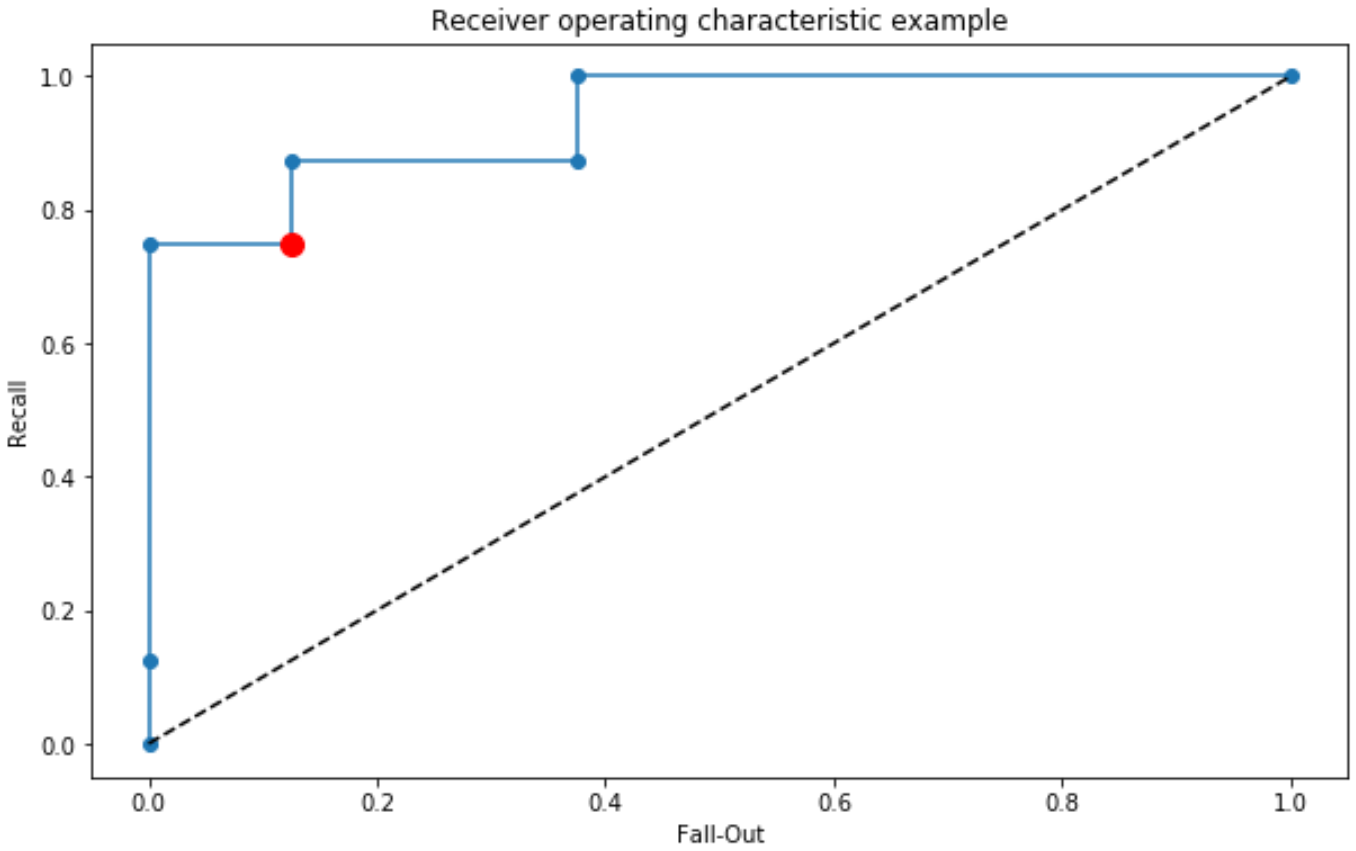
Receiver operating characteristic example
Recall
Fall-Out
0.0
0.2
0.4
0.6
0.8
1.0

ROC 커브 (9)

정확도, 정밀도, 재현도 등의 성능이 동일한 모형도, ROC 커브에서 살펴보면 성능이 다름

```
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
from sklearn.svm import SVC

X, y = make_classification(n_samples=1000,
    weights=[0.95, 0.05], random_state=5)

model1 = LogisticRegression().fit(X, y)
y_hat1 = model1.predict(X)

model2 = SVC(gamma=0.0001, C=3000, probability=True).fit(X, y)
y_hat2 = model2.predict(X)
```

```
print(confusion_matrix(y, y_hat1))
```

```
[[940   3]
 [ 30  27]]
```

```
print(confusion_matrix(y, y_hat2))
```

```
[[940   3]
 [ 30  27]]
```

ROC 커브 (10)

```
print(classification_report(y, model1.predict(X)))
```

	precision	recall	f1-score	support
0	0.97	1.00	0.98	943
1	0.90	0.47	0.62	57
accuracy			0.97	1000
macro avg	0.93	0.74	0.80	1000
weighted avg	0.97	0.97	0.96	1000

```
print(classification_report(y, model2.predict(X)))
```

	precision	recall	f1-score	support
0	0.97	1.00	0.98	943
1	0.90	0.47	0.62	57
accuracy			0.97	1000
macro avg	0.93	0.74	0.80	1000
weighted avg	0.97	0.97	0.96	1000

ROC 커브 (11)

```
plt.figure(figsize=(10,6))

fpr1, tpr1, thresholds1 = roc_curve(y, model1.decision_function(X))

fpr2, tpr2, thresholds1 = roc_curve(y, model2.decision_function(X))

plt.plot(fpr1, tpr1, 'o-', ms=2, label="Logistic Regression")
plt.plot(fpr2, tpr2, 'o-', ms=2, label="Kernel SVM")
plt.legend()
plt.plot([0, 1], [0, 1], 'k--', label="random guess")
plt.xlabel('Fall-Out')
plt.ylabel('Recall')
plt.title('ROC Curve')
plt.show()
```

ROC 커브 (12)

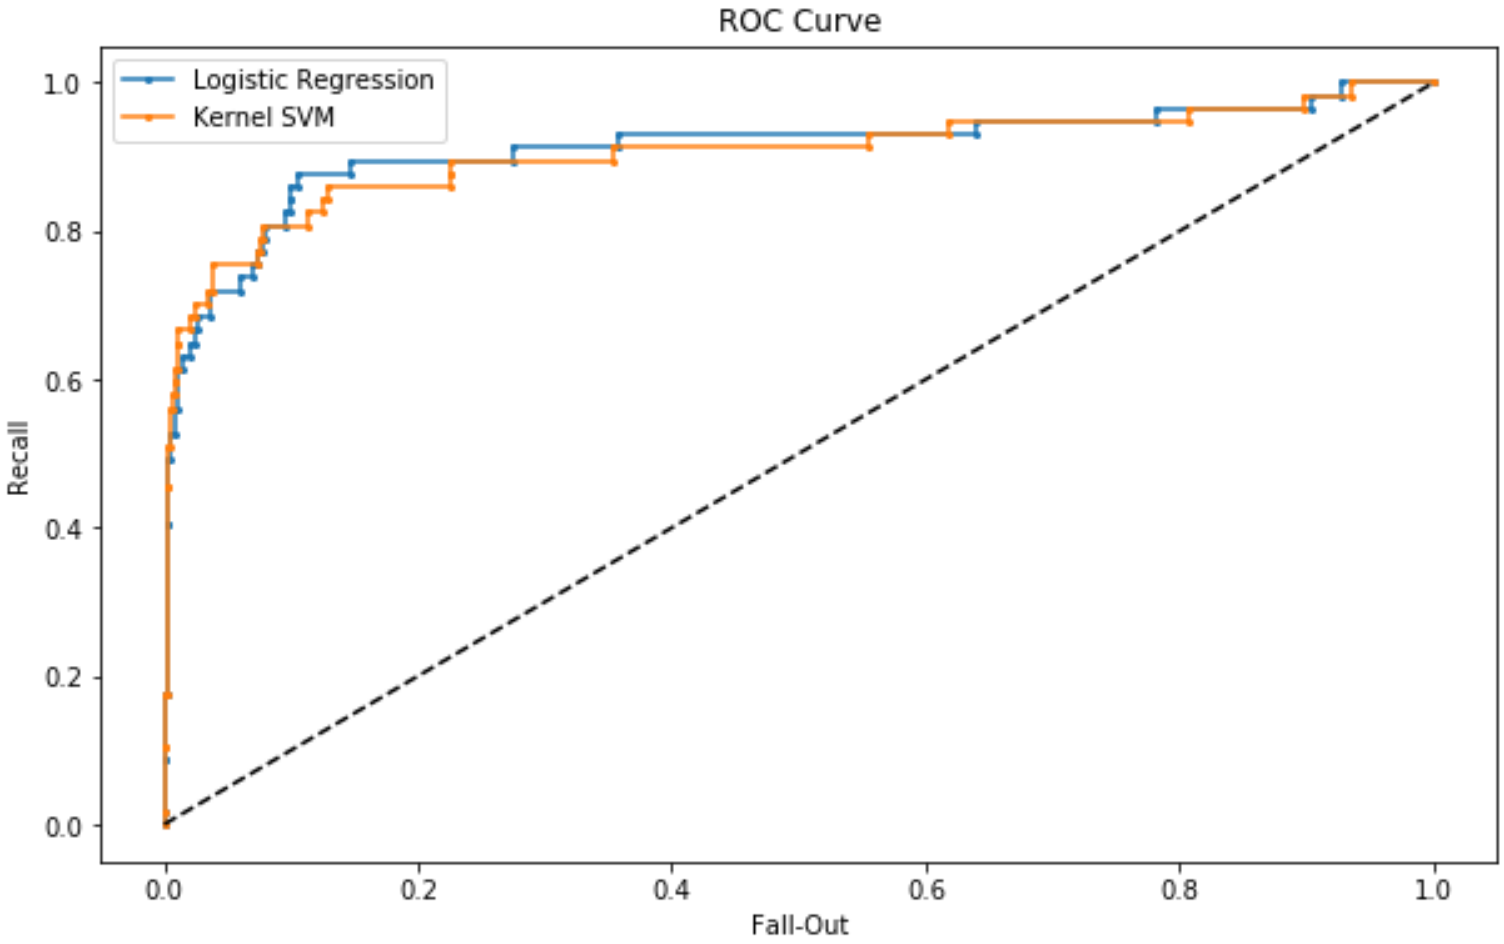
ROC Curve
Logistic Regression
Kernel SVM
Recall
Fall-Out
0.0
0.2
0.4
0.6
0.8
1.0

ROC 커브 (13)

AUC(Area Under the Curve)

- AUC는 ROC curve의 면적을 뜻한다.
- 위양성률값이 같을 때 재현률값이 크거나 재현률값이 같을 때 위양성률값이 작을수록
- AUC가 1에 가까운 값이고 좋은 모형이다.

```
from sklearn.metrics import auc
auc(fpr1, tpr1), auc(fpr2, tpr2)
```

20]: (0.9112202563673234, 0.9037227214377407)

ROC 커브 (14)

```
from sklearn.naive_bayes import GaussianNB
from sklearn.datasets import load_iris
from sklearn.preprocessing import label_binarize

iris = load_iris()
X = iris.data
y = label_binarize(iris.target, [0, 1, 2])

fpr = [None] * 3; tpr = [None] * 3; thr = [None] * 3

for i in range(3):
    model = GaussianNB().fit(X, y[:, i])
    fpr[i], tpr[i], thr[i] = roc_curve(y[:, i], model.predict_proba(X)[:, 1])
    plt.plot(fpr[i], tpr[i])

plt.xlabel('Fall-Out')
plt.ylabel('Recall')
plt.show()
```

ROC 커브 (15)

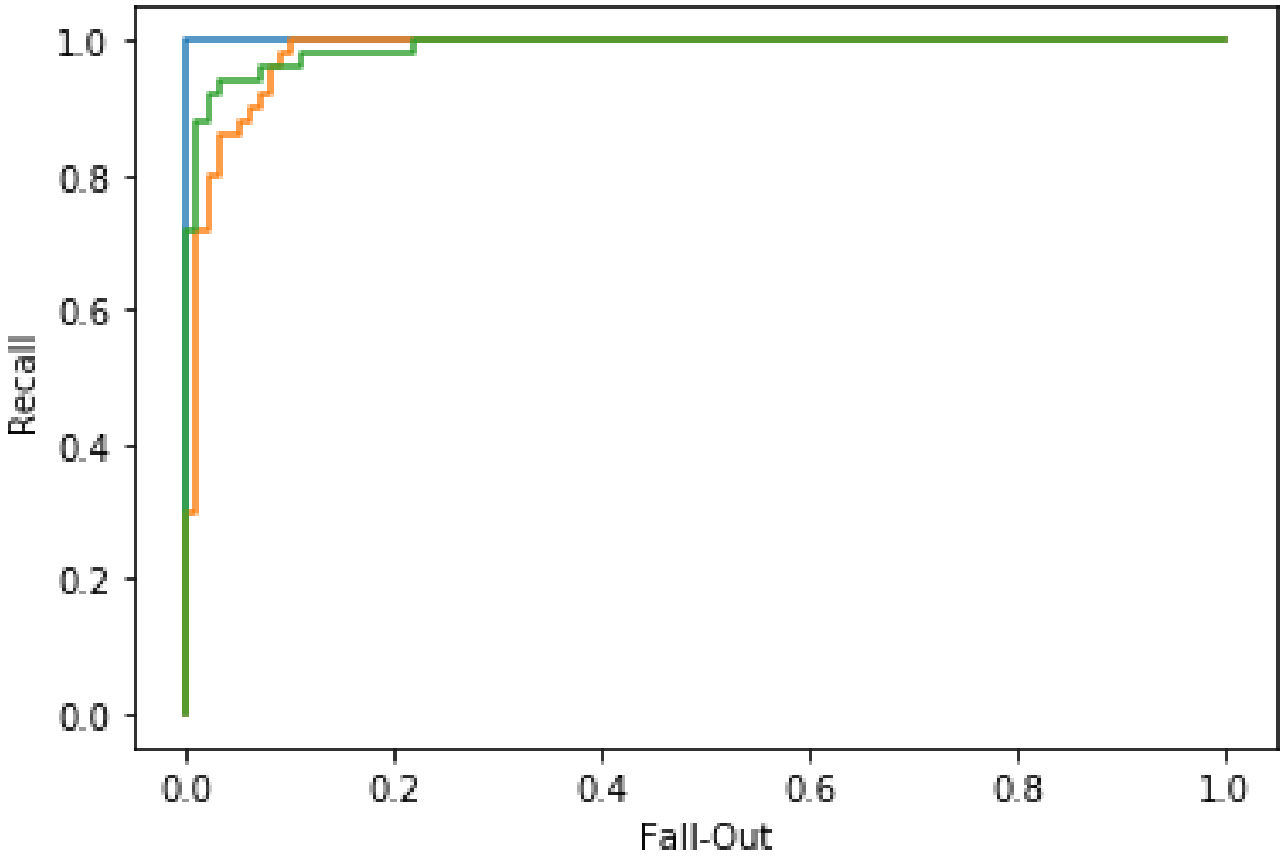

타이타닉 데이터의 정확도 이해

- **정확도(Accuracy)**
  - ✓ **예측결과가 동일한 테이터 건수 / 전체 예측 데이터 건수**
  - ✓ **이진분류 문제에 주로 사용하며**
  - ✓ **정확도 1개만 이용하여 모델의 성능을 왜곡하여 평가 할 수 있음**
    - 예제) 타이타닉의 여자 생존자를 레이블링
    - MNIST 데이터의 1개의 숫자를 분류하는 문제에서
- **장점**
  - ✓ **데이터가 균일할 때 좋다.**
- **단점**
  - ✓ **데이터가 불균형한(imbalaced)일 경우 문제가 발생**
  - ✓ **오차행렬과 F1 스코어가 필요**

혼동행렬 Confusion Matrix

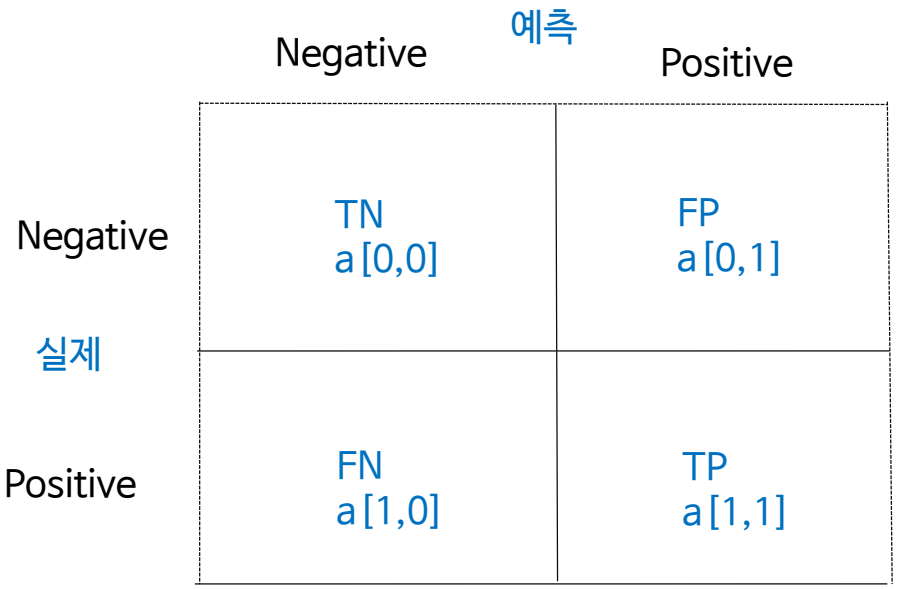

3-2 Confusion Matrix

```
from sklearn.metrics import confusion_matrix

# 앞절의 예측 결과인 fakepred와 실제 결과인 y_test의 Confusion Matrix출력
confusion_matrix(y_test , fakepred)
```

```
array([[405,   0],
       [ 45,   0]], dtype=int64)
```

정밀도와 재현율

- 정밀도 = TP/(FP+TP)
  - ✓ FP를 낮추는 데 초점
- 재현율 = TP/(FN+TP)
  - ✓ 재현율은 FN을 낮추는데 초점

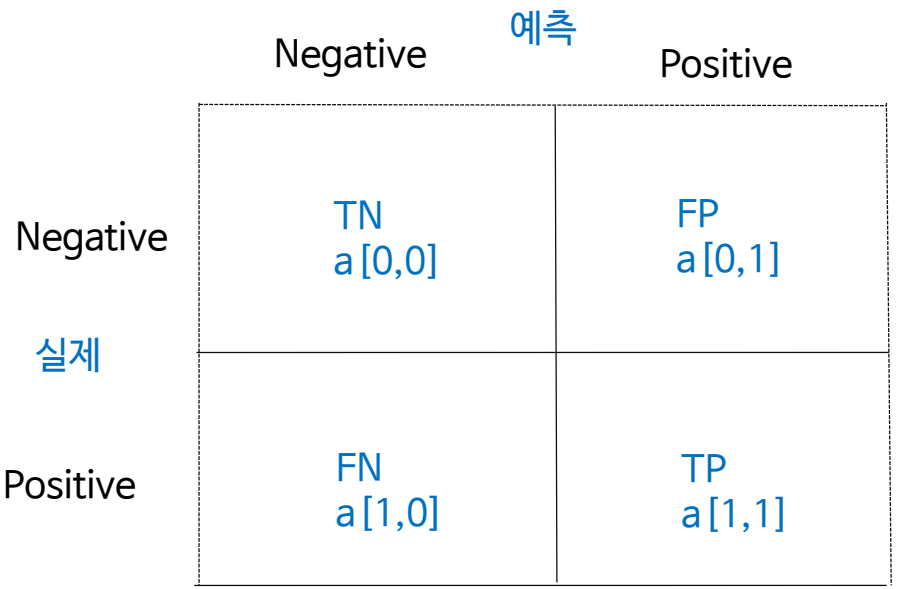

정밀도 계산

- precision_score()와 recall_score() API 제공
- 편리를 위해 get_elf_eval() 함수 만듬
  ✓ Confusion matrix, accuracy, precision, reacall을 한꺼번에 호출

3-3 Precision과 Recall

```
from sklearn.metrics import accuracy_score, precision_score , recall_score , confusion_matrix

def get_clf_eval(y_test , pred):
    confusion = confusion_matrix( y_test, pred)
    accuracy = accuracy_score(y_test , pred)
    precision = precision_score(y_test , pred)
    recall = recall_score(y_test , pred)
    print('오차 행렬')
    print(confusion)
    print('정확도: {0:.4f}, 정밀도: {1:.4f}, 재현율: {2:.4f}'.format(accuracy , precision ,recall))
```

정밀도 계산

```
import numpy as np
import pandas as pd

from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression

# 원본 데이터를 재로딩, 데이터 가공, 학습데이터/테스트 데이터 분할.
titanic_df = pd.read_csv('./input/train.csv')
y_titanic_df = titanic_df['Survived']
X_titanic_df= titanic_df.drop('Survived', axis=1)
X_titanic_df = transform_features(X_titanic_df)

X_train, X_test, y_train, y_test = train_test_split(X_titanic_df, y_titanic_df, ₩
                                                    test_size=0.20, random_state=11)

lr_clf = LogisticRegression()

lr_clf.fit(X_train , y_train)
pred = lr_clf.predict(X_test)
get_clf_eval(y_test , pred)
```

```
오차 행렬
[[104  14]
 [ 13  48]]
정확도: 0.8492, 정밀도: 0.7742, 재현율: 0.7869
```

정밀도/재현율 트레이드오프

- 사이킷럿 분류 알고리즘은 라벨(Label)을 결정 확률로 정함
  - ✓ (예) 임계값 50%로 두고, 51이상 확률이면 Positive, 이하면 Negative
  - ✓ predict_proba() 메서드 제공, 반환은 예측값이 아니고, 예측 확률을 제공.

정밀도/재현율 트레이드오프

Precision/Recall Trade-off

- 타이타닉의 로지스틱 회귀 객체에서 predict_proba()를 수행한 반환값

```
pred_proba = lr_clf.predict_proba(X_test)
pred  = lr_clf.predict(X_test)
print('pred_proba()결과 Shape : {0}'.format(pred_proba.shape))
print('pred_proba array에서 앞 3개만 샘플로 추출 ₩n:', pred_proba[:3])

# 예측 확률 array 와 예측 결과값 array 를 concatenate 하여 예측 확률과 결과값을 한눈에 확인
pred_proba_result = np.concatenate([pred_proba , pred.reshape(-1,1)],axis=1)
print('두개의 class 중에서 더 큰 확률을 클래스 값으로 예측 ₩n',pred_proba_result[:3])
```

LogisticRegression

확률계산

```
pred_proba()결과 Shape : (179, 2)
pred_proba array에서 앞 3개만 샘플로 추출
: [[0.46150057 0.53849943]
 [0.87861098 0.12138902]
 [0.87721519 0.12278481]]
두개의 class 중에서 더 큰 확률을 클래스 값으로 예측
 [[0.46150057 0.53849943 1.        ]
 [0.87861098 0.12138902 0.        ]
 [0.87721519 0.12278481 0.        ]]
```

2개 컬럼 합하면 1.
합은 1
합은 1

예측한 라벨

임계값을 정하기 (1)

- 임계값에 따라, 즉 예측 확률에 따라 예측값이 다름.
- Binarizer 클래스 이용
  - ✓ 지정된 임계값 보다 작으면 0, 크면 1을 반환
  - ✓ fit_transform()을 사용

```
from sklearn.preprocessing import Binarizer

X = [[ 1, -1,  2],
     [2,  0,  0],
     [ 0,  1.1, 1.2]]

# threshold 기준값보다 같거나 작으면 0을, 크면 1을 반환
binarizer = Binarizer(threshold=1.1)
print(binarizer.fit_transform(X))
```

```
[[0. 0. 1.]
 [1. 0. 0.]
 [0. 0. 1.]]
```

임계값이 1.1이고, 이 값보다 크면 1을 출력

임계값을 정하기 (2)

- 디폴트 임계값=0.5일때 타이타닉의 같은 혼동행렬 얻어야 함

```
from sklearn.preprocessing import Binarizer

#Binarizer의 threshold 설정값. 분류 결정 임곗값임.
custom_threshold = 0.5 ----------> 디폴트 임계값을 사용

# predict_proba( ) 반환값의 두번째 컬럼 ,
# 즉 Positive 클래스 컬럼 하나만 추출하여 Binarizer를 적용
pred_proba_1 = pred_proba[:,1].reshape(-1,1)

binarizer = Binarizer(threshold=custom_threshold).fit(pred_proba_1)
custom_predict = binarizer.transform(pred_proba_1)

get_clf_eval(y_test, custom_predict)
```

```
혼동행렬
[[104  14]
 [ 13  48]]
정확도: 0.8492, 정밀도: 0.7742, 재현율: 0.7869 ----------> 같은 값인지 확인
```

임계값을 정하기 (3)

```
# Binarizer의 threshold 설정값을 0.4로 설정. 즉 분류 결정 임곗값을 0.5에서 0.4로 낮춤
custom_threshold = 0.4                                    ----------> 새로운 임계값
pred_proba_1 = pred_proba[:,1].reshape(-1,1)              ----------> Positive 확률
binarizer = Binarizer(threshold=custom_threshold).fit(pred_proba_1)
custom_predict = binarizer.transform(pred_proba_1)

get_clf_eval(y_test , custom_predict)
```

```
혼동행렬
[[99 19]
 [10 51]]
정확도: 0.8380, 정밀도: 0.7286, 재현율: 0.8361
```

정밀도는 내려가고, 재현율은 올라간다.

임계값=0.4

```
혼동행렬
[[104  14]
 [ 13  48]]
정확도: 0.8492, 정밀도: 0.7742, 재현율: 0.7869
```

임계값=0.5

임계값과 정밀도/재현율 (1)

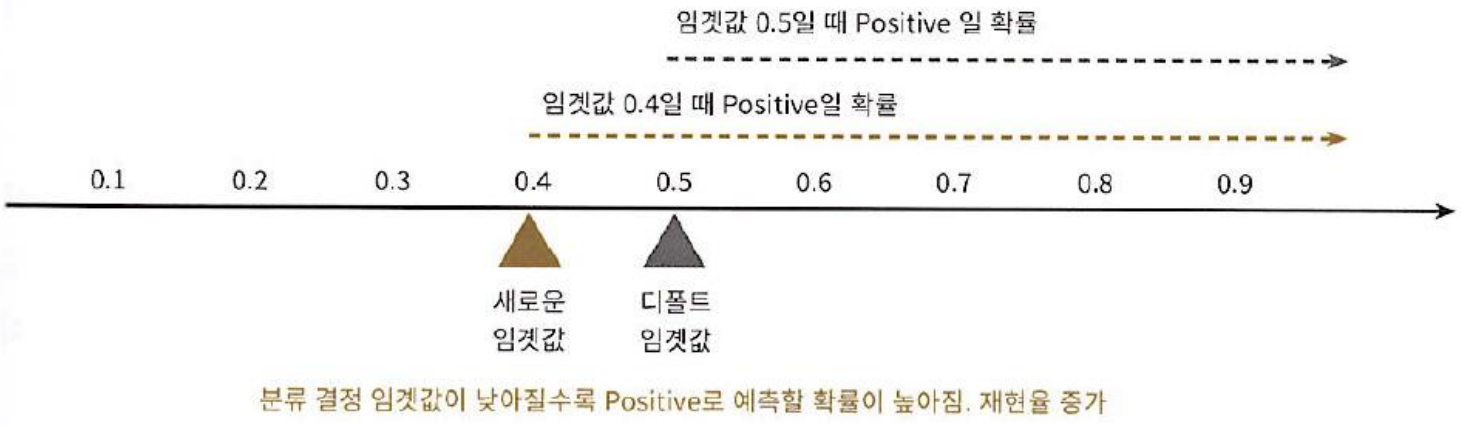

분류 결정 임곗값이 낮아질수록 Positive로 예측할 확률이 높아짐. 재현율 증가

임계값과 정밀도/재현율 (2)

```
from sklearn.metrics import precision_recall_curve

# 레이블 값이 1일때의 예측 확률을 추출
pred_proba_class1 = lr_clf.predict_proba(X_test)[:, 1]

# 실제값 데이터 셋과 레이블 값이 1일 때의 예측 확률을 precision_recall_curve 인자로 입력
precisions, recalls, thresholds = precision_recall_curve(y_test, pred_proba_class1 )
print('반환된 분류 결정 임곗값 배열의 Shape:', thresholds.shape)

#반환된 임계값 배열 로우가 147건이므로 샘플로 10건만 추출하되, 임곗값을 15 Step으로 추출.
thr_index = np.arange(0, thresholds.shape[0], 15)
print('샘플 추출을 위한 임계값 배열의 index 10개:', thr_index)
print('샘플용 10개의 임곗값: ', np.round(thresholds[thr_index], 2))

# 15 step 단위로 추출된 임계값에 따른 정밀도와 재현율 값
print('샘플 임계값별 정밀도: ', np.round(precisions[thr_index], 3))
print('샘플 임계값별 재현율: ', np.round(recalls[thr_index], 3))
```

```
반환된 분류 결정 임곗값 배열의 Shape: (143,)
샘플 추출을 위한 임계값 배열의 index 10개: [  0  15  30  45  60  75  90 105 120 135]
샘플용 10개의 임곗값:  [0.1  0.12 0.14 0.19 0.28 0.4  0.56 0.67 0.82 0.95]
샘플 임계값별 정밀도:  [0.389 0.44  0.466 0.539 0.647 0.729 0.836 0.949 0.958 1.   ]
샘플 임계값별 재현율:  [1.    0.967 0.902 0.902 0.902 0.836 0.754 0.607 0.377 0.148]
```

임계값과 정밀도/재현율 (3)

```
import matplotlib.pyplot as plt
import matplotlib.ticker as ticker
%matplotlib inline

def precision_recall_curve_plot(y_test , pred_proba_c1):
    # threshold ndarray와 이 threshold에 따른 정밀도, 재현율 ndarray 추출.
    precisions, recalls, thresholds = precision_recall_curve( y_test, pred_proba_c1)

    # X축을 threshold값으로, Y축은 정밀도, 재현율 값으로 각각 Plot 수행. 정밀도는 점선으로 표시
    plt.figure(figsize=(8,6))
    threshold_boundary = thresholds.shape[0]
    plt.plot(thresholds, precisions[0:threshold_boundary], linestyle='--', label='precision')
    plt.plot(thresholds, recalls[0:threshold_boundary],label='recall')

    # threshold 값 X 축의 Scale을 0.1 단위로 변경
    start, end = plt.xlim()
    plt.xticks(np.round(np.arange(start, end, 0.1),2))

    # x축, y축 label과 legend, 그리고 grid 설정
    plt.xlabel('Threshold value'); plt.ylabel('Precision and Recall value')
    plt.legend(); plt.grid()
    plt.show()

precision_recall_curve_plot( y_test, lr_clf.predict_proba(X_test)[:, 1] )
```

임계값과 정밀도/재현율 (4)

문제: 어떻게 정밀도와 재현율의 수치가 적절하게 조합돼 분류의 종합적인 성능평가에 사용할 것인가?

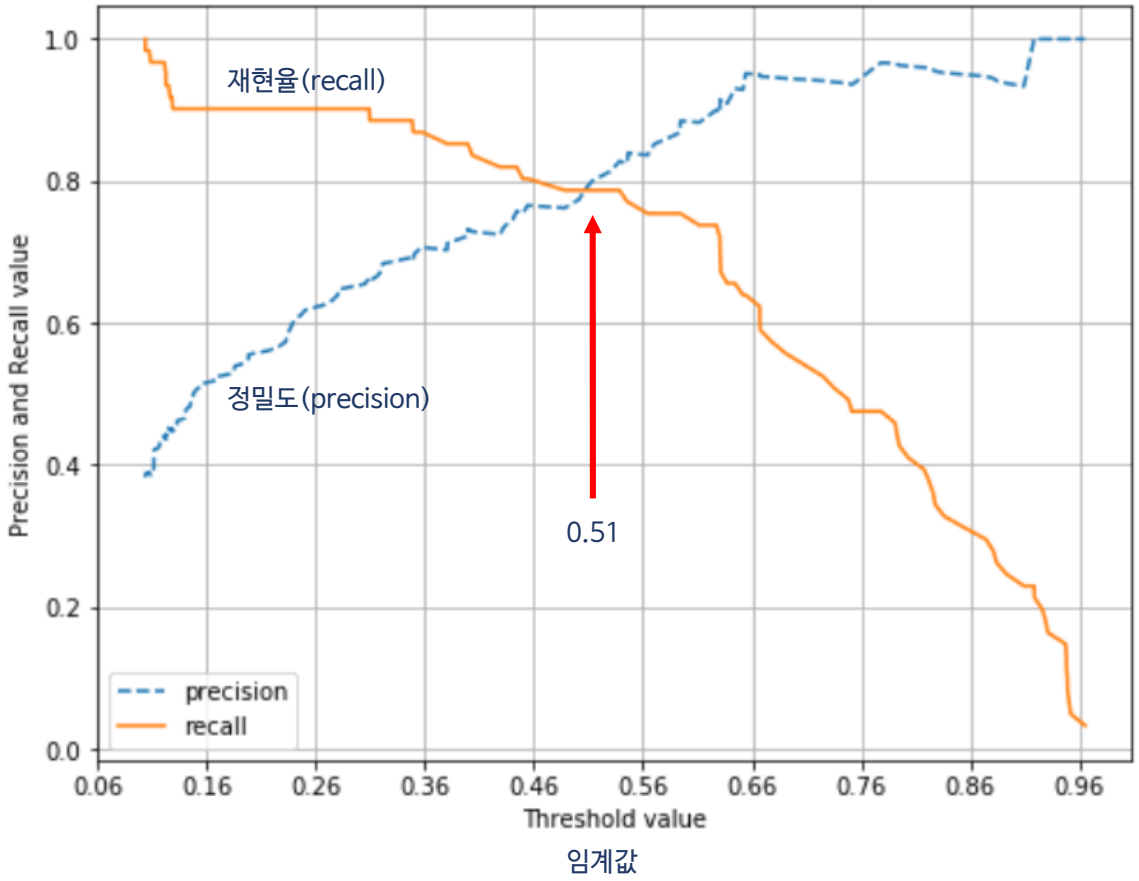

F1 스코어

- f1_score() API 제공
  - ✓ 정밀도와 재현율을 결합한 지료
  - ✓ 어느 한쪽으로 치우치지 않는 수치를 나타낼 때 상대적으로 높은 값을 가짐

$$F1 = 2 \times \frac{\text{precision} \times \text{recall}}{\text{precison} + \text{recall}}$$

조화평균(Harmonic Mean)

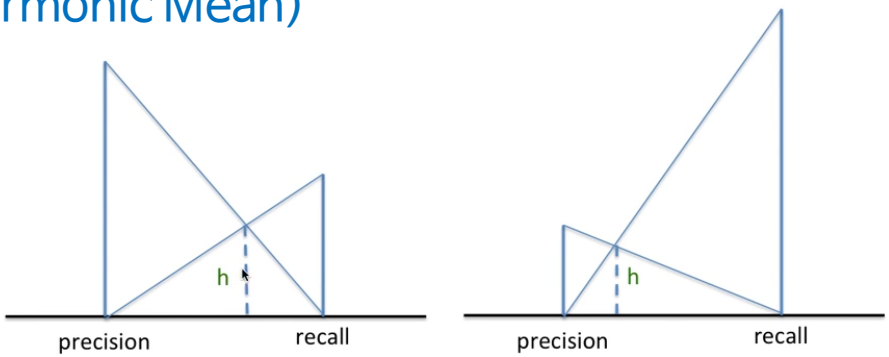

h is half the harmonic mean

$$\text{F1 Score} = 2 \text{ X } \frac{\text{Precision X Recall}}{\text{Precision + Recall}}$$

F1 score

3.4 F1 Score ¶

```
from sklearn.metrics import f1_score
f1 = f1_score(y_test , pred)
print('F1 스코어: {0:.4f}'.format(f1))
```

```
F1 스코어: 0.7805
```

F1 값이 최대일때, 임계값은 얼마인가?

```
오차 행렬
[[109   9]
 [ 15  46]]
정확도: 0.8659, 정밀도: 0.8364, 재현율: 0.7541, F1:0.7931
임계값: 0.6
오차 행렬
[[112   6]
 [ 16  45]]
정확도: 0.8771, 정밀도: 0.8824, 재현율: 0.7377, F1:0.8036
임계값: 0.65
오차 행렬
[[115   3]
 [ 22  39]]
정확도: 0.8603, 정밀도: 0.9286, 재현율: 0.6393, F1:0.7573
임계값: 0.7
오차 행렬
[[116   2]
 [ 28  33]]
정확도: 0.8324, 정밀도: 0.9429, 재현율: 0.5410, F1:0.6875
```

최대 F1

최대 임계값

```
def get_clf_eval(y_test , pred):
    confusion = confusion_matrix( y_test, pred)
    accuracy = accuracy_score(y_test , pred)
    precision = precision_score(y_test , pred)
    recall = recall_score(y_test , pred)
    # F1 스코어 추가
    f1 = f1_score(y_test,pred)
    print('오차 행렬')
    print(confusion)
    # f1 score print 추가
    print('정확도: {0:.4f}, 정밀도: {1:.4f}, 재현율: {2:.4f}, F1:{3:.4f}'.format(accuracy, precision, recall, f1))

thresholds = [0.3, 0.35, 0.4 , 0.45 , 0.50 , 0.55 , 0.60, 0.65, 0.7]
pred_proba = lr_clf.predict_proba(X_test)
get_eval_by_threshold(y_test, pred_proba[:,1].reshape(-1,1), thresholds)
```

ROC 커브와 AUC (1)

- ROC (Receiver Operation Characteristic Curve)
  - ✓ 수신자 판단 곡선
  - ✓ x 축: FPR(False Positive Rate)
    - TNR(True Negative Rate)은 특이성(Specificity)라고 부름
    - FPR=FP/(FP+TN)=1-TNR = 1-특이성
  - ✓ y 축: TPR(True Positive Rate)
    - TPR은 recall(재현율)이다, 민감도(Sensitivity)라고 부름
  - ✓ ROC 곡선이 직선일 경우 (AUC=0.5)
    - 모델 예측 성능은 떨어짐

- 제공 API : roc_curve()

ROC 커브와 AUC (2)

- 분류의 판단 기준은 FPR과 TPR 변화를 면적 지표로 사용
- AUC (Area Under Curve)
  - ✓ 가운데 대각선 ROC 커브의 경우, 면적은 반. 즉 0.5이다.
  - ✓ AUC 면적이 1이면 성능이 좋다.

ROC 커브와 AUC (3)

문제1) 타이타닉 생존자 예측의 FPR, TPR, 임계값을 구하라

```
from sklearn.metrics import roc_curve

# 레이블 값이 1일때의 예측 확률을 추출
pred_proba_class1 = lr_clf.predict_proba(X_test)[:, 1]

fprs , tprs , thresholds = roc_curve(y_test, pred_proba_class1)
# 반환된 임곗값 배열 로우가 47건이므로 샘플로 10건만 추출하되, 임곗값을 5 Step으로 추출.
thr_index = np.arange(0, thresholds.shape[0], 5)
print('샘플 추출을 위한 임곗값 배열의 index 10개:', thr_index)
print('샘플용 10개의 임곗값: ', np.round(thresholds[thr_index], 2))

# 5 step 단위로 추출된 임계값에 따른 FPR, TPR 값
print('샘플 임곗값별 FPR: ', np.round(fprs[thr_index], 3))
print('샘플 임곗값별 TPR: ', np.round(tprs[thr_index], 3))
```

```
샘플 추출을 위한 임곗값 배열의 index 10개: [ 0  5 10 15 20 25 30 35 40 45 50]
샘플용 10개의 임곗값:  [1.97 0.75 0.63 0.59 0.49 0.4  0.31 0.15 0.12 0.11 0.1 ]
샘플 임곗값별 FPR:  [0.    0.017 0.034 0.051 0.127 0.161 0.237 0.483 0.61  0.703 0.814]
샘플 임곗값별 TPR:  [0.    0.475 0.672 0.754 0.787 0.852 0.885 0.902 0.934 0.967 0.984]
```

ROC 커브와 AUC (4)

문제1) 타이타닉 생존자 예측의 FPR, TPR, 임계값을 구하라

```
from sklearn.metrics import roc_curve  ----------> ROC API

# 레이블 값이 1일때의 예측 확률을 추출
pred_proba_class1 = lr_clf.predict_proba(X_test)[:, 1]

fprs , tprs , thresholds = roc_curve(y_test, pred_proba_class1)
# 반환된 임곗값 배열 로우가 47건이므로 샘플로 10건만 추출하되, 임곗값을 5 Step으로 추출.
thr_index = np.arange(0, thresholds.shape[0], 5)
print('샘플 추출을 위한 임곗값 배열의 index 10개:', thr_index)
print('샘플용 10개의 임곗값: ', np.round(thresholds[thr_index], 2))

# 5 step 단위로 추출된 임계값에 따른 FPR, TPR 값
print('샘플 임곗값별 FPR: ', np.round(fprs[thr_index], 3))
print('샘플 임곗값별 TPR: ', np.round(tprs[thr_index], 3))
```

```
샘플 추출을 위한 임곗값 배열의 index 10개: [ 0  5 10 15 20 25 30 35 40 45 50]
샘플용 10개의 임곗값:  [1.97 0.75 0.63 0.59 0.49 0.4  0.31 0.15 0.12 0.11 0.1 ]
샘플 임곗값별 FPR:  [0.    0.017 0.034 0.051 0.127 0.161 0.237 0.483 0.61  0.703 0.814]
샘플 임곗값별 TPR:  [0.    0.475 0.672 0.754 0.787 0.852 0.885 0.902 0.934 0.967 0.984]
```

ROC 커브와 AUC (5)

```
def roc_curve_plot(y_test , pred_proba_c1):
    # 임곗값에 따른 FPR, TPR 값을 반환 받음.
    fprs , tprs , thresholds = roc_curve(y_test ,pred_proba_c1)

    # ROC Curve를 plot 곡선으로 그림.
    plt.plot(fprs , tprs, 'r-', label='ROC')
    # 가운데 대각선 직선을 그림.
    plt.plot([0, 1], [0, 1], 'b--', label='Random')

    # FPR X 축의 Scale을 0.1 단위로 변경, X,Y 축명 설정등
    start, end = plt.xlim()
    plt.xticks(np.round(np.arange(start, end, 0.1),2))
    plt.xlim(0,1); plt.ylim(0,1)
    plt.xlabel('FPR( 1 - Sensitivity )'); plt.ylabel('TPR( Recall )')
    plt.legend()
    plt.show()

roc_curve_plot(y_test, lr_clf.predict_proba(X_test)[:, 1] )
```

ROC 커브와 AUC (6)

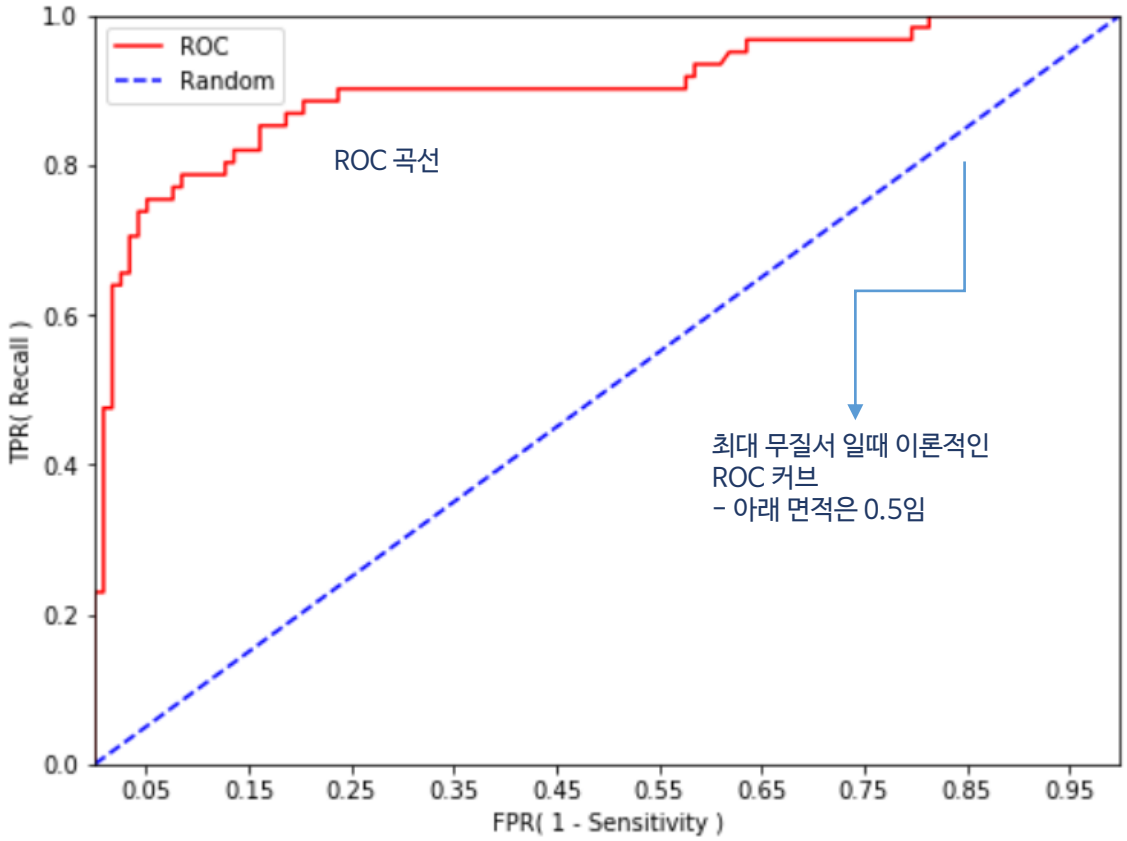
ROC
Random
ROC 곡선
최대 무질서 일때 이론적인
ROC 커브
- 아래 면적은 0.5임
TPR(Recall)
FPR(1 - Sensitivity)
0.0
0.2
0.4
0.6
0.8
1.0
0.05
0.15
0.25
0.35
0.45
0.55
0.65
0.75
0.85
0.95

ROC 커브와 AUC (7)

```
from sklearn.metrics import roc_auc_score

pred = lr_clf.predict(X_test)
roc_score = roc_auc_score(y_test, pred)
print('ROC AUC 값: {0:.4f}'.format(roc_score))
```

```
ROC AUC 값: 0.8341
```

```
def get_clf_eval(y_test , pred):
    confusion = confusion_matrix( y_test, pred)
    accuracy = accuracy_score(y_test , pred)
    precision = precision_score(y_test , pred)
    recall = recall_score(y_test , pred)
    f1 = f1_score(y_test,pred)
    # ROC-AUC 추가
    roc_auc = roc_auc_score(y_test, pred)
    print('오차 행렬')
    print(confusion)
    # ROC-AUC print 추가
    print('정확도: {0:.4f}, 정밀도: {1:.4f}, 재현율: {2:.4f},₩
    F1: {3:.4f}, AUC:{4:.4f}'.format(accuracy, precision, recall, f1, roc_auc))
```

Kaggle – Pima 인디언 당료병 예측

- Kaggle에서 Pima 인디언 당료병 예측 코드와 데이터 받음
  ✓ Tutorial을 다운로드 받아본다.

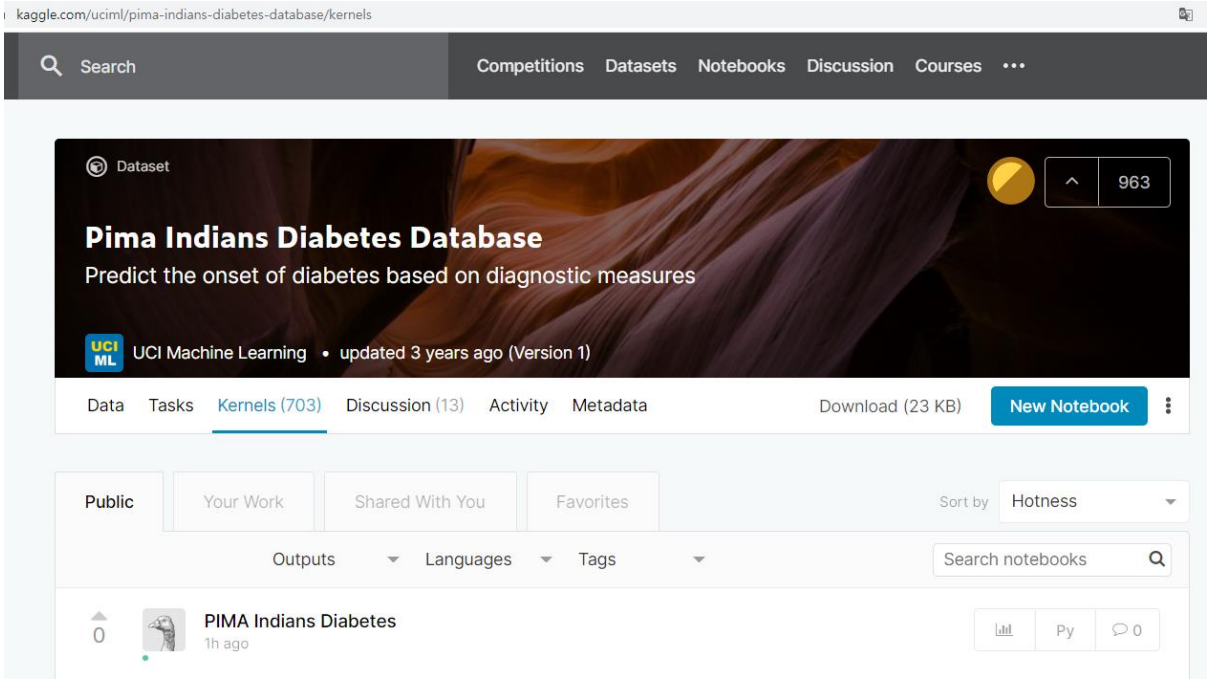

(숙제) pima 인디언 당료병 예측(1)

3-6 (연습문제) 피마 인디언 당료병 예측

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
%matplotlib inline

from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score, precision_score, recall_score, roc_auc_score
from sklearn.metrics import f1_score, confusion_matrix, precision_recall_curve, roc_curve

from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
```

```
diabetes_data = pd.read_csv('./input/diabetes.csv')
print(diabetes_data['Outcome'].value_counts())
```

Kaggle에서 파일을 다운로드하고,
저장 위치를 input 폴더 안에 저장함.

```
0    500
1    268
Name: Outcome, dtype: int64
```

(숙제) pima 인디언 당료병 예측(1)

임신횟수 포도당 부하 검사 수치 혈압(mm Hg) 피하지방 혈청 인슐린 체질량지수 당뇨 내력 가중치 값 나이 라벨

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
0	6	148.0	72.0	35.000000	79.799479	33.6	0.627	50	1
1	1	85.0	66.0	29.000000	79.799479	26.6	0.351	31	0
2	8	183.0	64.0	20.536458	79.799479	23.3	0.672	32	1
3	1	89.0	66.0	23.000000	94.000000	28.1	0.167	21	0
4	0	137.0	40.0	35.000000	168.000000	43.1	2.288	33	1

```
diabetes_data.info( )
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 768 entries, 0 to 767
Data columns (total 9 columns):
Pregnancies                 768 non-null int64
Glucose                     768 non-null int64
BloodPressure               768 non-null int64
SkinThickness               768 non-null int64
Insulin                     768 non-null int64
BMI                         768 non-null float64
DiabetesPedigreeFunction    768 non-null float64
Age                         768 non-null int64
Outcome                     768 non-null int64
dtypes: float64(2), int64(7)
memory usage: 54.1 KB
```

(숙제) pima 인디언 당료병 예측(2)

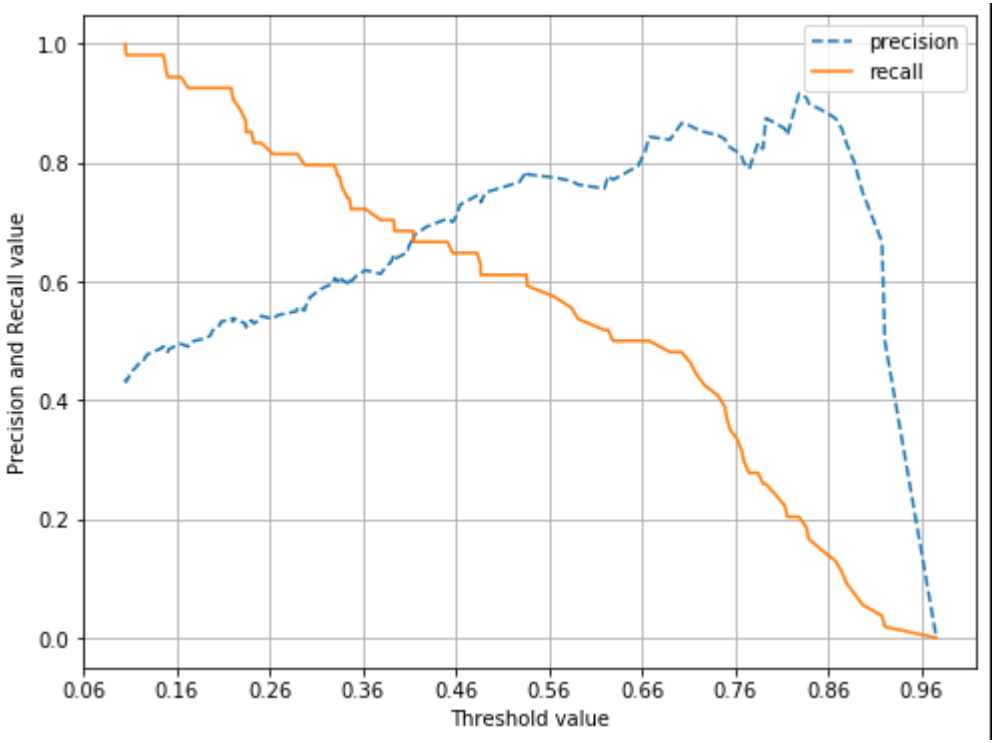

3장 요약

- 이진 분류의 경우 데이터가 불균형일때,
  - ✓ 정확도 혼자서는 충분하지 않음
- 오차행렬, 정밀도, 재현율
  - ✓ 정밀도와 재현율(recall)은 Positive 데이터에 초점을 맞춘 평가지표
  - ✓ 임계밀도를 조정하여 정밀도와 재현율 수치를 제어
- F1 스코어
  - ✓ 정밀도와 재현율을 결합한 평가 지표이며, 어느 한쪽으로 치우치지 않을때 높은 값
- ROC-AUC 곡선
  - ✓ 일반적으로 이진 분류의 성능 평가로 가장 많이 사용하는 지표
  - ✓ AUC 값은 ROC 곡선 밑의 면적을 구한 것으로, 1에 가까울 수록 성능이 좋다.

Thank You!

www.ust.ac.kr